

فصل دوم: مبانی نظری و پیشینه تحقیق

۲-۱- مقدمه

در این فصل پایه‌های نظری کار و پژوهش‌های مرتبط با آن مرور می‌شود. سیستمی که در این پایان‌نامه ساخته شده از چند بخش تشکیل شده است: داده‌ای که از حرکت واقعی دوربین روی دست جمع‌آوری می‌شود، روشی برای جدا کردن حرکت عمودی از حرکت ارگانیک در این داده، یک مدل یادگیری عمیق که از تصویر و تاریخچه حرکت استفاده می‌کند، و در نهایت ارزیابی این مدل از نظر طبیعی بودن و ایجاد نکردن ناراحتی برای بیننده. به همین دلیل، این فصل هم به موضوعات بینایی ماشین و یادگیری عمیق می‌پردازد و هم به موضوعاتی مثل ویژگی‌های حرکت بدن انسان، پردازش سیگنال و بیماری حرکتی.

ترتیب مطالب به این صورت است. در بخش ۲-۲ ویژگی‌های حرکت دوربین روی دست و روش جدا کردن «قصد» از «حرکت ارگانیک» توضیح داده می‌شود؛ این بخش در واقع مبنای تعریف مسئله در این پژوهش است. در بخش ۲-۳ روش‌هایی که در صنعت بازی و انیمیشن برای کنترل و زنده کردن حرکت دوربین به کار می‌روند مرور می‌شوند. بخش ۲-۴ به ابزارهای یادگیری عمیقی که در مدل پیشنهادی استفاده شده‌اند، یعنی شبکه‌های باقی‌مانده، واحد بازگشتی در پیچ‌دار و سازوکار توجه، اختصاص دارد. در بخش ۲-۵ بیماری حرکتی و روش‌های سنجش آن بررسی می‌شود. بخش ۲-۶ پژوهش‌های داده‌محوری را که به موضوع این پایان‌نامه نزدیک هستند مرور می‌کند و در بخش ۲-۷ جمع‌بندی فصل همراه با یک جدول مقایسه‌ای ارائه می‌شود.

۲-۲- حرکت دوربین روی دست و اجزای آن

۲-۲-۱- اجزای حرکت دوربین روی دست

وقتی فیلم برداری دوربین را در دست می گیرد و راه می رود، چرخش دوربین حاصل جمع چند حرکت با منشأ متفاوت است. مهم ترین بخش آن حرکت عمودی است؛ یعنی جایی که فیلم بردار می خواهد نگاه کند، مثل چرخاندن دوربین به سمت یک شخص یا دنبال کردن یک سوژه متحرک. این حرکت معمولاً آرام و با فرکانس پایین است. در کنار آن، چند حرکت ناخواسته هم وجود دارد که فیلم بردار کنترل مستقیمی روی آن ها ندارد.

اولین مورد حرکت ناشی از راه رفتن است. در هر گام، بدن و سر کمی بالا و پایین می روند و این حرکت به دست و دوربین هم منتقل می شود. هیراساکی و همکاران (Hirasaki et al., ۱۹۹۹) حرکت سر و بدن را در سرعت های مختلف راه رفتن اندازه گرفتند. نتایج آن ها نشان داد که افراد برای سریع تر راه رفتن بیشتر طول گام را زیاد می کنند تا فرکانس آن را، و فرکانس غالب حرکت سر در حدود دو هرتز باقی می ماند. با افزایش سرعت، دامنه جابه جایی عمودی سر بیشتر می شود و در سرعت های بالاتر سر با چرخش در جهت عمودی (pitch) این جابه جایی را جبران می کند تا نگاه پایدار بماند. بنابراین انتظار می رود بخشی از انرژی حرکت دوربین در حدود دو هرتز دیده شود.

مورد دوم لرزش فیزیولوژیک دست است. حتی وقتی فرد تلاش می کند دستش را کاملاً ثابت نگه دارد، دست لرزش بسیار کوچکی دارد. مک آلی و مارسدن (McAuley & Marsden, ۲۰۰۰) توضیح می دهند که این لرزش یک جزء مکانیکی-بازتابی دارد که به جرم و سختی اندام بستگی دارد، و یک جزء مرکزی که مربوط به نوسان های سیستم عصبی مرکزی در محدوده حدود ۱۰ هرتز است. دامنه این لرزش کم است، اما چون دوربین آن را به چرخش تصویر تبدیل می کند، در تصویر نهایی قابل مشاهده است.

مورد سوم حرکات اصلاحی است. وقتی فیلم بردار دوربین را سریع می چرخاند، معمولاً کمی از هدف رد می شود و بعد برمی گردد، یا پیش از رسیدن به نقطه مورد نظر کمی مکث می کند. این جزء از نظر فرکانسی جای مشخصی

ندارد، اما به حرکت عمودی وابسته است؛ یعنی بعد از چرخش‌های تند بیشتر دیده می‌شود. به نظر می‌رسد همین وابستگی یکی از چیزهایی است که حرکت دوربین واقعی را از نویز تصادفی متمایز می‌کند. جدول ۱-۲ این اجزا را خلاصه کرده است.

جدول ۱-۲- اجزای حرکت دوربین روی دست

منشأ	محدوده تقریبی فرکانس	جزء حرکت
تصمیم فیلم‌بردار برای نگاه کردن به یک نقطه	کمتر از حدود ۱ هرتز	حرکت عمودی (قصد)
بالا و پایین رفتن بدن و جبران آن توسط سر و دست	حدود ۱ تا ۳ هرتز (هم‌گام با قدم‌ها)	حرکت ناشی از راه رفتن
رد شدن از هدف و برگشتن، مکث پیش از توقف	متغیر، وابسته به حرکت عمودی	حرکات اصلاحی
سیستم عصبی-عضلانی	در محدوده حدود ۱۰ هرتز	لرزش فیزیولوژیک دست

یک نکته عملی در اینجا نرخ نمونه‌برداری است. داده‌های این پژوهش در نرخ ۳۰ فریم بر ثانیه استفاده می‌شوند، بنابراین طبق قضیه نمونه‌برداری فقط فرکانس‌های کمتر از ۱۵ هرتز قابل نمایش هستند. این محدوده جزء راه رفتن و حرکات اصلاحی را به‌طور کامل پوشش می‌دهد و محدوده حدود ۱۰ هرتز لرزش فیزیولوژیک را هم در بر می‌گیرد. از طرف دیگر، تصویر نهایی بازی هم با نرخ در همین حدود به بیننده نمایش داده می‌شود، پس فرکانس‌های بالاتر عملاً در خروجی دیده نمی‌شوند.

۲-۲-۲- اندازه‌گیری چرخش دوربین با ژيروسکوپ

برای اینکه بتوان حرکت دوربین روی دست را یاد گرفت، باید چرخش دوربین در هر فریم با دقت خوبی اندازه‌گیری شود. تلفن‌های همراه امروزی یک ژيروسکوپ سه‌محوره دارند که سرعت زاویه‌ای دستگاه را با نرخ چند صد نمونه در ثانیه اندازه می‌گیرد. کارپنکو و همکاران (Karpenko et al., ۲۰۱۱) نشان دادند که با انتگرال‌گیری از خروجی ژيروسکوپ بین زمان ثبت فریم‌ها می‌توان چرخش دوربین را به‌طور دقیق به دست آورد و از آن برای تثبیت ویدیو و اصلاح اعوجاج شاتر غلتان استفاده کرد. اگر $\omega(t)$ سرعت زاویه‌ای حول یک محور و t_k زمان ثبت فریم k باشد، چرخش دوربین بین دو فریم متوالی برابر است با:

$$\Delta\theta_k = \int_{t_k}^{t_{k+1}} \omega(t) dt \quad (2-1)$$

در عمل، ژيروسکوپ سرعت زاویه‌ای را در دستگاه مختصات خود گوشه‌ای اندازه می‌گیرد، در حالی که برای کنترل دوربین بازی، چرخش افقی (yaw) باید حول محور قائم جهان تعریف شود. برای تبدیل این دو به یکدیگر می‌توان جهت گرانث را از خروجی شتاب‌سنج که با یک فیلتر پایین‌گذر هموار شده است تخمین زد و سرعت زاویه‌ای را روی آن تصویر کرد. نکته دیگری که کارپنکو و همکاران به آن اشاره کرده‌اند، اختلاف زمانی کوچک بین برچسب زمانی فریم و لحظه واقعی ثبت تصویر است. اگر این اختلاف جبران نشود، چرخش محاسبه‌شده با تصویر کمی ناهمگام خواهد بود. در فصل سوم روش اندازه‌گیری و جبران این اختلاف برای داده‌های این پژوهش شرح داده می‌شود.

۲-۲-۳- جدا کردن قصد از حرکت ارگانیکی

در بیشتر روش‌های تثبیت ویدیو، مسیر حرکت دوربین به دو بخش تقسیم می‌شود: یک مسیر هموار که فرض می‌شود همان حرکت مورد نظر فیلم‌بردار است، و باقی‌مانده‌ای که به‌عنوان لرزش ناخواسته حذف می‌شود. کارپنکو و همکاران (Karpenko et al., ۲۰۱۱) برای به دست آوردن مسیر هموار از یک فیلتر گاوسی روی چرخش‌ها استفاده

کردند. گراندمن و همکاران (Grundmann et al., ۲۰۱۱) مسیر هموار را با یک بهینه‌سازی به دست آوردند که مسیر را به قطعه‌های ثابت، خطی و سهمی تقسیم می‌کند، با این استدلال که فیلم‌برداران حرفه‌ای هم از همین نوع حرکات، یعنی دوربین ثابت، پن‌یکنواخت و شروع و توقف نرم، استفاده می‌کنند.

این پژوهش از همین ایده استفاده می‌کند، اما هدفش برعکس تثبیت ویدیو است. در تثبیت ویدیو باقی‌مانده دور ریخته می‌شود؛ در این پژوهش، باقی‌مانده همان چیزی است که باید یاد گرفته شود. به عبارت دیگر، در بازی قصد بازیکن از ماوس به دست می‌آید و مدل باید باقی‌مانده‌ای را تولید کند که یک فیلم‌بردار انسانی با همان قصد روی دوربین ایجاد می‌کرد. اگر $\Delta\theta_n$ چرخش دوربین در فریم n باشد، این تجزیه به صورت زیر نوشته می‌شود:

$$(۲-۲) \quad \Delta\theta_n^{int} = (h_{LP} * \Delta\theta)_n$$

$$(۲-۳) \quad r_n = \Delta\theta_n - \Delta\theta_n^{int}$$

که در آن $\Delta\theta_n^{int}$ سهم قصد، r_n باقی‌مانده یا همان حرکت ارگانیك، h_{LP} یک فیلتر پایین‌گذر و علامت * عمل کانولوشن را نشان می‌دهد. برای این فیلتر، فیلتر باتروورث (Butterworth, ۱۹۳۰) انتخاب شده است. پاسخ دامنه این فیلتر در باند عبور تا جای ممکن صاف است و در نتیجه دامنه حرکت عمودی را تغییر نمی‌دهد. پاسخ دامنه فیلتر باتروورث مرتبه N با فرکانس قطع ω_c به صورت زیر است:

$$(۲-۴) \quad |H(j\omega)|^2 = \frac{1}{1 + (\omega/\omega_c)^{2N}}$$

یک مشکل فیلترهای علی این است که فاز سیگنال را تغییر می‌دهند؛ یعنی مسیر هموار شده کمی از مسیر واقعی عقب می‌افتد. اگر این تأخیر اصلاح نشود، بخشی از حرکت عمودی به اشتباه در باقی‌مانده قرار می‌گیرد. برای رفع این مشکل، فیلتر یک بار در جهت رفت و یک بار در جهت برگشت روی سیگنال اعمال می‌شود (Gustafsson, ۱۹۹۶). پاسخ کلی در این حالت فاز صفر دارد و دامنه آن مجذور دامنه فیلتر اولیه است:

$$(۲-۵) \quad H_{ff}(j\omega) = |H(j\omega)|^2$$

این روش در بیومکانیک هم برای هموار کردن داده‌های حرکتی بدن انسان رایج است (Winter, ۲۰۰۹). فرکانس قطع باید طوری انتخاب شود که حرکت عمدی کاملاً در مسیر هموار باقی بماند و حرکت ناشی از راه رفتن، که حدود دو هرتز است، به باقی مانده منتقل شود. با توجه به جدول ۱-۲، فرکانس قطع ۱ هرتز در این پژوهش انتخاب شده است. باید توجه داشت که فیلتر رفت و برگشت به نمونه‌های آینده نیاز دارد و فقط برای برچسب‌گذاری داده‌ها به صورت آفلاین قابل استفاده است. در زمان اجرا نیازی به آن نیست، چون قصد مستقیماً از حرکت ماوس بازیکن به دست می‌آید.

۲-۳- روش‌های رایج کنترل و زنده‌سازی دوربین در بازی و انیمیشن

۲-۳-۱- روش‌های مبتنی بر قید

در این روش‌ها، کنترل دوربین به صورت یک مسئله بهینه‌سازی تعریف می‌شود. طراح به جای تعیین مستقیم موقعیت و جهت دوربین، ویژگی‌هایی را که تصویر باید داشته باشد به صورت قید مشخص می‌کند؛ مثلاً اندازه سوژه در کادر، زاویه دید نسبت به کاراکتر، یا اینکه هیچ مانعی جلوی سوژه قرار نگیرد. سپس سیستم در هر لحظه موقعیتی را پیدا می‌کند که بیشترین تعداد قیدها را برآورده کند. کریستی و همکاران (Christie et al., ۲۰۰۸) در مرور جامع خود این روش‌ها و روش‌های مشابه را دسته‌بندی کرده‌اند. نقطه قوت این روش‌ها کادربندی دقیق و قابل پیش‌بینی است، اما با پیچیده‌تر شدن صحنه، هزینه محاسباتی آن‌ها زیاد می‌شود. علاوه بر این، خروجی آن‌ها از نظر هندسی درست است ولی ویژگی‌های حرکت دوربین انسانی را ندارد. این روش‌ها بیشتر برای دوربین سوم شخص و سینمایی به کار می‌روند؛ در دوربین اول شخص، جهت دوربین را بازیکن تعیین می‌کند و مسئله اصلی چگونگی حرکت دوربین است، نه اینکه دوربین کجا قرار بگیرد.

۲-۳-۲- مدل‌های فیزیکی

روش رایج دیگر در بازی‌ها استفاده از مدل‌های فیزیکی ساده است. هیگ-هاچینسون (Haigh-Hutchinson, ۲۰۰۹) در کتاب خود که یکی از مراجع اصلی طراحی دوربین در بازی است، استفاده از فنرها و روش‌های هموارسازی و میرایی را برای دنبال کردن هدف توضیح می‌دهد. یکی از ساده‌ترین شکل‌های این ایده، سیستم جرم-فنر-میراگر است. در این مدل، دوربین مانند جرمی در نظر گرفته می‌شود که با یک فنر به هدف وصل شده است:

$$\ddot{x} = k(x_{target} - x) - c\dot{x} \quad (۲-۶)$$

که در آن x موقعیت یا زاویه دوربین، x_{target} مقدار هدف، k سختی فنر و c ضریب میرایی است. این مدل باعث می‌شود دوربین کمی دیرتر از هدف حرکت کند و آرام متوقف شود؛ در بازی‌ها معمولاً به این رفتار «تأخیر دوربین» (camera lag) گفته می‌شود. این روش حرکت را نرم‌تر می‌کند، اما ماهیت آن فقط هموارسازی است و چیزی به حرکت اضافه نمی‌کند. رفتار آن هم کاملاً قطعی است؛ یعنی یک ورودی مشخص همیشه یک خروجی مشخص تولید می‌کند.

۲-۳-۳- نویز رویه‌ای و Camera Shake

برای ایجاد حس دوربین روی دست، رایج‌ترین روش اضافه کردن نویز به چرخش دوربین است. نویز پرلین (Perlin, ۱۹۸۵) به این دلیل انتخاب محبوبی است که برخلاف نویز تصادفی ساده پیوسته است و تغییرات ناگهانی ندارد. آیزرلو (Eiserloh, ۲۰۱۶) در ارائه شناخته‌شده خود در کنفرانس GDC روشی را پیشنهاد کرد که در آن یک متغیر به نام «ضربه» (trauma) با هر رویداد مثل انفجار یا برخورد افزایش پیدا می‌کند و به تدریج کم می‌شود. دامنه لرزش متناسب با توان دوم (یا سوم) این متغیر تعیین می‌شود و شکل لرزش از نویز پرلین گرفته می‌شود، چون به گفته او نویز پیوسته برای لرزش صفحه بسیار بهتر از نویز تصادفی است:

$$\theta(t) = A_{max} \cdot T^2 \cdot P(f t) \quad (۲-۷)$$

که در آن T مقدار ضربه (عددی بین صفر و یک)، A_{max} بیشینه دامنه، f فرکانس نویز و P تابع نویز پرلین است. در آنریل انجین هم قابلیت به نام Camera Shake وجود دارد که الگوهای آماده‌ای مانند نویز پرلین و موج سینوسی در اختیار طراح قرار می‌دهد (Epic Games, n.d.).

این روش‌ها ساده و ارزان هستند، اما دو محدودیت اصلی دارند که در فصل اول هم به آن‌ها اشاره شد. اول اینکه پارامترهای نویز مستقل از وضعیت بازی هستند؛ لرزش هنگام ایستادن، راه رفتن یا چرخش تند یکسان است، مگر اینکه طراح برای هر حالت جداگانه پارامتر تعریف کند. دوم اینکه نویز به حرکت عمودی ربطی ندارد، در حالی که در بخش ۲-۲-۱ دیدیم که بخشی از حرکت واقعی دوربین، یعنی حرکات اصلاحی، مستقیماً به حرکت عمودی وابسته است.

۲-۳-۴- نوسان دوربین در ناوبری اول شخص

پژوهش‌هایی هم وجود دارند که به‌طور مستقیم اثر نوسان دوربین را بر تجربه کاربر در محیط‌های مجازی اول شخص بررسی کرده‌اند. لکوییر و همکاران (Lécuyer et al., ۲۰۰۶) نوسان‌هایی در سه جهت عمودی، جانبی و رو به جلو به دوربین اضافه کردند و نشان دادند که این نوسان‌ها حس راه رفتن را در کاربر تقویت می‌کنند. شرکت‌کنندگان همه حالت‌های نوسانی را به حرکت خطی بدون نوسان ترجیح دادند و در بین آن‌ها نوسان عمودی بیشترین ترجیح را داشت. در آزمایش دوم، یک حرکت جبرانی در جهت دوربین هم اضافه شد که نگاه را روی یک نقطه ثابت نگه می‌داشت و این حالت هم نتیجه مثبتی داشت. ترزیمان و همکاران (Terziman et al., ۲۰۱۳) این کار را ادامه دادند و نوسان‌ها را به ویژگی‌های کاراکتر (مثل قد، وزن، سن، جنسیت، میزان آمادگی جسمانی و خستگی) و حالت حرکت (راه رفتن، دویدن و دوی سریع) وابسته کردند. نتایج آن‌ها نشان داد که کاربران می‌توانند حالت‌های مختلف حرکت و بعضی از ویژگی‌های کاراکتر مثل سن و آمادگی جسمانی را از روی حرکت دوربین تشخیص دهند.

این دو پژوهش از دو جهت برای این پایان نامه اهمیت دارند. از یک طرف نشان می دهند که حرکت دوربین، اگر درست طراحی شود، واقعاً روی تجربه کاربر اثر مثبت دارد. از طرف دیگر، در هر دو کار شکل نوسانها با توابع ریاضی و پارامترهایی که پژوهشگران دستی تنظیم کرده اند ساخته شده است. سؤالی که این پایان نامه مطرح می کند این است که آیا می توان این رفتار را به طور مستقیم از داده های حرکت واقعی یاد گرفت.

۲-۴- ابزارهای یادگیری عمیق در مدل پیشنهادی

مدل پیشنهادی سه بخش اصلی دارد: یک شبکه کانولوشنی که ویژگی های تصویر را استخراج می کند، یک شبکه بازگشتی که تاریخچه حرکت را خلاصه می کند، و یک لایه توجه متقاطع که این دو را به هم مرتبط می کند. در این بخش مبانی هر یک از این سه بخش مرور می شود. جزئیات پیاده سازی در فصل سوم آمده است.

۲-۴-۱- شبکه های باقی مانده (ResNet)

شبکه های عصبی کانولوشنی ابزار استاندارد استخراج ویژگی از تصویر هستند. تا پیش از سال ۲۰۱۶، عمیق تر کردن این شبکه ها با مشکلی همراه بود که هی و همکاران (He et al., ۲۰۱۶) آن را «تخریب» (degradation) نامیدند: با افزایش تعداد لایه ها از حدی به بعد، خطای آموزش هم بیشتر می شد. نکته مهم این است که خود نویسندگان تأکید می کنند این مشکل از محو شدن گرادیان ناشی نمی شود، چون با استفاده از نرمال سازی دسته ای (batch normalization) سیگنال ها در شبکه به خوبی منتقل می شوند. به نظر آن ها مشکل اصلی این است که بهینه ساز در پیدا کردن جواب مناسب برای شبکه های خیلی عمیق دچار مشکل می شود.

راه حل پیشنهادی آن ها یادگیری باقی مانده است. اگر $H(x)$ نگاشتی باشد که چند لایه متوالی باید یاد بگیرند، به جای یادگیری مستقیم آن، لایه ها تابع $F(x) = H(x) - x$ را یاد می گیرند و ورودی از طریق یک اتصال میان بر به خروجی اضافه می شود:

$$(۲-۸) \quad H(x) = F(x) + x$$

اگر بهترین نگاشت برای یک بلوک نزدیک به نگاشت همانی باشد، کافی است لایه‌ها $F(x)$ را به صفر نزدیک کنند که کار ساده‌تری است. در حالت کلی، خروجی یک بلوک باقی‌مانده به صورت زیر نوشته می‌شود:

$$(۲-۹) \quad y = F(x, \{W_i\}) + W_s x$$

که W_s یک نگاشت خطی است و فقط زمانی استفاده می‌شود که ابعاد ورودی و خروجی بلوک با هم برابر نباشند (He et al., ۲۰۱۶).

در این پژوهش از نسخه ۱۸ لایه این شبکه (ResNet-۱۸) استفاده شده که از قبل روی مجموعه داده ImageNet (Deng et al., ۲۰۰۹) آموزش دیده است. وزن‌های این شبکه در طول آموزش ثابت نگه داشته می‌شوند. دلیل این انتخاب این است که داده‌های این پژوهش در مقایسه با ImageNet بسیار محدود هستند و آموزش کامل یک شبکه کانولوشنی با این مقدار داده به احتمال زیاد به بیش‌برازش منجر می‌شود. علاوه بر این، ویژگی‌های شبکه‌هایی که روی ImageNet آموزش دیده‌اند برای بسیاری از کاربردهای دیگر هم مناسب هستند. خروجی آخرین بلوک کانولوشنی این شبکه یک نقشه ویژگی ۷ در ۷ است که هر خانه آن به یک ناحیه از تصویر مربوط است. در مدل پیشنهادی، این ۴۹ خانه به عنوان ۴۹ نشانه (token) در لایه توجه استفاده می‌شوند.

۲-۴-۲- شبکه‌های بازگشتی و واحد بازگشتی در پیچه‌دار (GRU)

شبکه‌های بازگشتی برای پردازش دنباله‌ها طراحی شده‌اند و در هر گام زمانی یک حالت پنهان را به‌روز می‌کنند که خلاصه‌ای از ورودی‌های قبلی است. شبکه‌های بازگشتی ساده در یادگیری وابستگی‌های طولانی مدت مشکل دارند، چون گرادیان در طول گام‌های زمانی متوالی یا خیلی کوچک یا خیلی بزرگ می‌شود. شبکه حافظه کوتاه مدت طولانی یا LSTM (Hochreiter & Schmidhuber, ۱۹۹۷) این مشکل را با یک سلول حافظه و در پیچه‌های ورودی و

خروجی حل کرد. در پیچه فراموشی بعدها توسط گرس و همکاران (Gers et al., ۲۰۰۰) به این ساختار اضافه شد و نسخه رایج امروزی LSTM سه در پیچه دارد.

چو و همکاران (Cho et al., ۲۰۱۴) واحد بازگشتی ساده‌تری با دو در پیچه پیشنهاد کردند که بعدها با نام واحد بازگشتی در پیچه‌دار یا GRU شناخته شد (Chung et al., ۲۰۱۴). در GRU سلول حافظه جداگانه وجود ندارد و فقط دو در پیچه به کار می‌رود. در پیچه به‌روزرسانی در واقع نقش دو در پیچه فراموشی و ورودی LSTM را با هم انجام می‌دهد و مشخص می‌کند چه مقدار از حالت قبلی حفظ شود و چه مقدار از اطلاعات جدید جایگزین آن شود. در پیچه بازنشانی تعیین می‌کند که در محاسبه حالت جدید، چه مقدار از حالت قبلی در نظر گرفته شود. روابط GRU در گام زمانی t به صورت زیر است:

$$(۲-۱۰) \quad z_t = \sigma(W_z x_t + U_z h_{t-1} + b_z)$$

$$(۲-۱۱) \quad r_t = \sigma(W_r x_t + U_r h_{t-1} + b_r)$$

$$(۲-۱۲) \quad \tilde{h}_t = \tanh(W_h x_t + U_h(r_t \odot h_{t-1}) + b_h)$$

$$(۲-۱۳) \quad h_t = (1 - z_t) \odot h_{t-1} + z_t \odot \tilde{h}_t$$

که در آن x_t ورودی گام t ، h_{t-1} حالت پنهان قبلی، σ تابع سیگموئید و $\odot$ ضرب درایه‌به‌درایه است. W و U ماتریس‌های وزن و b بردارهای بایاس هستند. باید توجه داشت که نقش z_t و $1 - z_t$ در رابطه آخر در منابع مختلف گاهی جابه‌جا نوشته می‌شود؛ مثلاً در مقاله اصلی چو و همکاران و در پیاده‌سازی کتابخانه PyTorch عکس رابطه بالا است. این تفاوت فقط یک قرارداد است و تأثیری روی توانایی شبکه ندارد، چون شبکه در طول آموزش خودش را با آن تطبیق می‌دهد.

چانگ و همکاران (Chung et al., ۲۰۱۴) عملکرد GRU و LSTM را روی چند نوع داده دنباله‌ای مقایسه کردند و نشان دادند که هر دو از شبکه بازگشتی ساده بهتر عمل می‌کنند، اما هیچ کدام در همه موارد برتری قطعی ندارند. با

این حال، GRU پارامترهای کمتری دارد و سریع‌تر اجرا می‌شود. برای این پژوهش که مدل باید در کنار رندر بازی و در کمتر از یک فریم اجرا شود، این ویژگی اهمیت زیادی دارد. دنباله‌ای که در این پژوهش به GRU داده می‌شود کوتاه است (۱۰ گام زمانی، معادل یک سوم ثانیه)، بنابراین مشکل وابستگی‌های طولانی مدت در اینجا جدی نیست و یک GRU کوچک برای آن کافی است.

۲-۴-۳- سازوکار توجه و توجه متقاطع

سازوکار توجه روشی است که به مدل اجازه می‌دهد از میان مجموعه‌ای از بردارها، به‌طور پویا آن‌هایی را که برای یک پرسش مشخص مهم‌تر هستند انتخاب کند. واسوانی و همکاران (Vaswani et al., ۲۰۱۷) در معماری ترنسفورمر فرم «توجه ضرب نقطه‌ای مقیاس شده» را معرفی کردند. در این فرم، هر پرسش (query) با همه کلیدها (key) مقایسه می‌شود، نتیجه با تابع softmax به وزن تبدیل می‌شود و خروجی میانگین وزن دار مقادیر (value) است:

$$Attention(Q, K, V) = softmax(\frac{QK^T}{\sqrt{d_k}})V \quad (2-14)$$

در این رابطه d_k بعد بردارهای کلید است. تقسیم بر $\sqrt{d_k}$ برای این است که وقتی بعد بردارها بزرگ است، حاصل ضرب نقطه‌ای مقادیر خیلی بزرگی پیدا نکند؛ در غیر این صورت تابع softmax وارد ناحیه‌ای می‌شود که گرادیان آن بسیار کوچک است. واسوانی و همکاران همچنین نشان دادند که بهتر است به جای یک توجه با بعد کامل، چند توجه موازی با بعد کوچک‌تر، که «سر» (head) نامیده می‌شوند، استفاده شود تا هر سر بتواند روی نوع متفاوتی از رابطه تمرکز کند:

$$MultiHead(Q, K, V) = Concat(head_1, \dots, head_h)W^O \quad (2-15)$$

$$head_i = Attention(QW_i^Q, KW_i^K, VW_i^V) \quad (2-16)$$

اگر Q ، K و V همگی از یک دنباله گرفته شوند، به آن خودتوجهی (self-attention) گفته می‌شود. در توجه متقاطع (cross-attention)، پرسش از یک منبع و کلید و مقدار از منبع دیگری گرفته می‌شوند. در مدل پیشنهادی

این پژوهش، پرسش از خروجی GRU، یعنی خلاصه حرکت اخیر دوربین، ساخته می شود و کلید و مقدار از ۴۹ نشانه تصویری ResNet به دست می آیند. به این ترتیب، مدل می تواند بر اساس نوع حرکتی که در جریان است، مثلاً چرخش به یک سمت، مشخص کند کدام نواحی تصویر برای پیش بینی حرکت بعدی اهمیت بیشتری دارند. وزن های توجه، که برای هر فریم ۴۹ عدد هستند، را می توان نمایش داد و بررسی کرد که مدل در هر لحظه به کدام قسمت تصویر توجه کرده است. در فصل چهارم از این امکان برای تحلیل رفتار مدل استفاده می شود.

۲-۵- بیماری حرکتی و سنجش آن

۲-۵-۱- نظریه های بیماری حرکتی

بیماری حرکتی در محیط های مجازی، که با نام های بیماری شبیه ساز یا بیماری سایبری هم شناخته می شود، مجموعه ای از علائم مانند حالت تهوع، سرگیجه، سردرد و خستگی چشم است که ممکن است هنگام تماشای حرکت در محیط مجازی ایجاد شود (LaViola, ۲۰۰۰). برای توضیح علت این پدیده دو نظریه اصلی وجود دارد. نظریه تعارض حسی (Reason & Brand, ۱۹۷۵) رایج ترین توضیح است. طبق این نظریه، وقتی اطلاعاتی که از سیستم بینایی دریافت می شود با اطلاعات سیستم دهلیزی گوش داخلی هماهنگ نباشد، بیماری حرکتی ایجاد می شود. مثلاً وقتی کاربر روی صندلی نشسته است اما تصویر حرکت می کند، چشم حرکت را گزارش می کند در حالی که گوش داخلی حرکتی حس نمی کند.

نظریه ناپایداری قامتی (Riccio & Stoffregen, ۱۹۹۱) این توضیح را نقد می کند. طرفداران این نظریه معتقدند که تعارض بین حواس در زندگی روزمره هم زیاد پیش می آید و همیشه به بیماری منجر نمی شود. به نظر آنها، علت اصلی این است که فرد نمی تواند در شرایط جدید تعادل بدن خود را به خوبی کنترل کند، و ناپایداری در کنترل تعادل پیش از بروز علائم بیماری دیده می شود. استافرگن و همکاران (Stoffregen et al., ۲۰۰۸) این پیش بینی را در

بازی‌های کنسولی آزمایش کردند و مشاهده کردند که الگوی نوسان بدن در افرادی که بعداً بیمار شدند، پیش از بروز علائم با بقیه تفاوت داشت.

صرف نظر از اینکه کدام نظریه درست‌تر باشد، هر دو به یک نتیجه عملی می‌رسند که برای این پژوهش مهم است: حرکت تصویر در دوربین اول شخص می‌تواند باعث ناراحتی کاربر شود، و اضافه کردن لرزش به دوربین ممکن است این مشکل را بیشتر کند. چانگ و همکاران (Chang et al., ۲۰۲۰) در مرور خود عوامل مؤثر بر بیماری سایبری را بررسی کرده‌اند که از جمله آن‌ها می‌توان به ویژگی‌های حرکت دوربین، تأخیر سیستم و میدان دید اشاره کرد. به همین دلیل در این پژوهش، علاوه بر طبیعی بودن حرکت، میزان ناراحتی بیننده هم اندازه‌گیری می‌شود. همچنین در مقایسه‌ها، دامنه حرکت در همه روش‌ها برابر در نظر گرفته می‌شود تا تفاوت‌ها فقط به شکل حرکت مربوط باشد و نه به مقدار آن.

۲-۵-۲- ابزارهای سنجش

رایج‌ترین ابزار برای اندازه‌گیری بیماری حرکتی پرسش‌نامه SSQ است (Kennedy et al., ۱۹۹۳). در این پرسش‌نامه، شرکت‌کننده شدت ۱۶ علامت را در یک مقیاس چهارسطحی گزارش می‌کند و از روی پاسخ‌ها سه زیرمقیاس (حالت تهوع، مشکلات بینایی و بی‌جهتی) و یک نمره کل محاسبه می‌شود. برای ارزیابی کیفیت ادراک شده ویدیو، توصیه ITU-T P.۹۱۰ روش‌های استاندارد مانند امتیازدهی مطلق به هر کلیپ و مقایسه زوجی کلیپ‌ها را پیشنهاد می‌کند (ITU-T, ۲۰۲۳). این روش‌ها برای آزمون کاربری این پژوهش که در آن شرکت‌کنندگان کلیپ‌هایی از شرایط مختلف دوربین را تماشا می‌کنند مناسب هستند. برای سنجش غوطه‌وری هم پرسش‌نامه جنت و همکاران (Jennett et al., ۲۰۰۸) وجود دارد، اما این پرسش‌نامه برای تجربه بازی کردن طراحی شده است و در آزمونی که فقط شامل تماشای کلیپ‌های کوتاه است، کاربرد محدودی دارد. به همین دلیل در این پژوهش از سؤال‌های امتیازدهی مستقیم درباره طبیعی بودن حرکت و احساس حضور استفاده می‌شود.

۲-۶- پژوهش‌های داده‌محور مرتبط

۲-۶-۱- یادگیری رفتار دوربین از فیلم برداری انسان

چند پژوهش تلاش کرده‌اند رفتار فیلم‌برداران حرفه‌ای را از داده یاد بگیرند. هوانگ و همکاران (Huang et al., ۲۰۱۹) سیستمی برای فیلم برداری از حرکت انسان با پهنای طراحی کردند که از روی ویدیوهای فیلم برداری حرفه‌ای آموزش می‌بیند. ورودی مدل آن‌ها موقعیت اسکلت دوبعدی سوژه، ویژگی‌های تصویر پس‌زمینه و حرکت قبلی دوربین به شکل جریان نوری است. یک شبکه ConvLSTM دنباله‌به‌دنباله از این ورودی‌ها حرکت بعدی دوربین را پیش‌بینی می‌کند. ساختار این کار، یعنی ترکیب تصویر با تاریخچه حرکت برای پیش‌بینی حرکت بعدی، به این پژوهش شبیه است، اما هدف آن کادربندی سوژه است و نه جزئیات حرکت دوربین روی دست.

جیانگ و همکاران (Jiang et al., ۲۰۲۰) روشی ارائه دادند که رفتار دوربین را از کلیپ‌های فیلم‌های سینمایی استخراج می‌کند و آن را به صحنه‌های انیمیشن سه‌بعدی منتقل می‌کند. در این روش ابتدا حرکت دوربین و موقعیت بازیگران در فیلم مرجع تخمین زده می‌شود و سپس یک شبکه «ترکیب خبرگان» (mixture of experts) یاد می‌گیرد که همان سبک حرکت را در صحنه جدید تولید کند. این کار نشان می‌دهد که می‌توان سبک حرکت دوربین را از داده یاد گرفت و به محیط مجازی منتقل کرد، اما تمرکز آن هم روی حرکت‌های کلان دوربین در سطح نما است.

شی و همکاران (Xie et al., ۲۰۲۳) در چارچوب GAIT تولید مسیر دوربین در محیط‌های داخلی سه‌بعدی را با یادگیری تقویتی مدل کردند. پاداش مدل از یک شبکه ارزیابی زیبایی‌شناختی تصویر به دست می‌آید و دو جمله تنظیم هم برای تشویق تنوع مسیر و جریمه شتاب‌های ناگهانی به آن اضافه شده است. نتایج آزمون کاربری این پژوهش نشان داد که مسیرهای تولیدشده از نظر کاربران طبیعی‌تر هستند. نکته جالب در این کار این است که برای جلوگیری از حرکت رباتیک، به‌طور مشخص یک جمله نرمی به تابع هدف اضافه شده است؛ ایده‌ای مشابه در تابع هزینه این پایان‌نامه هم استفاده شده است.

۲-۶-۲- حرکت داده‌محور در بازی‌ها

در انیمیشن کاراکتر، جایگزینی روش‌های دستی با روش‌های داده‌محور سابقه طولانی‌تری دارد. هولدن و همکاران (Holden et al., ۲۰۱۷) شبکه‌ای به نام PFNN معرفی کردند که از داده‌های موشن کپچر آموزش می‌بیند و در زمان اجرا، بر اساس فرمان بازیکن و شکل زمین، حرکت کاراکتر را تولید می‌کند. این مدل با سرعت کافی برای اجرا در بازی کار می‌کند و حرکات حاصل از آن جزئیاتی دارند که ساختن آن‌ها با روش‌های دستی دشوار است. رابطه این کار با پایان‌نامه حاضر در ساختار مسئله است: بازیکن قصد را مشخص می‌کند (جهت و سرعت حرکت) و مدل جزئیات طبیعی را اضافه می‌کند. تفاوت در این است که آنجا خروجی حرکت کاراکتر است و اینجا حرکت دوربین.

۲-۶-۳- پردازش داده‌های حسگر حرکتی با یادگیری عمیق

داده‌های ژيروسکوپ و شتاب‌سنج در حوزه تشخیص فعالیت انسان به‌طور گسترده با یادگیری عمیق پردازش شده‌اند. اوردونیز و روژن (Ordóñez & Roggen, ۲۰۱۶) معماری DeepConvLSTM را پیشنهاد کردند که لایه‌های کانولوشنی را برای استخراج ویژگی‌های محلی از سیگنال حسگر با لایه‌های بازگشتی برای مدل کردن وابستگی زمانی ترکیب می‌کند. هامرلا و همکاران (Hammerla et al., ۲۰۱۶) شبکه‌های تمام‌متصل، کانولوشنی و بازگشتی را روی چند مجموعه داده حسگرهای پوشیدنی مقایسه کردند و نشان دادند که شبکه‌های بازگشتی در فعالیت‌های کوتاهی که ترتیب زمانی طبیعی دارند به‌طور قابل توجهی از شبکه‌های کانولوشنی بهتر عمل می‌کنند، در حالی که برای فعالیت‌های طولانی و تکراری مثل راه رفتن، شبکه‌های کانولوشنی مناسب‌تر بودند. این کارها برای تشخیص نوع فعالیت طراحی شده‌اند و نه تولید سیگنال، اما نشان می‌دهند که شبکه‌های بازگشتی ابزار مناسبی برای یادگیری الگوهای زمانی در داده‌های حسگر حرکتی هستند.

۲-۶-۴- پیش‌بینی توجه بصری انسان

یکی از فرض‌های این پژوهش این است که محتوای تصویر روی حرکت دوربین اثر دارد؛ مثلاً وقتی یک شخص در کادر دیده می‌شود، فیلم‌بردار ممکن است ناخودآگاه دوربین را کمی به سمت او متمایل کند. پژوهش‌های پیش‌بینی برجستگی بصری (saliency) نشان داده‌اند که ویژگی‌های شبکه‌های کانولوشنی از پیش‌آموزش دیده با نقاطی که انسان به آن‌ها نگاه می‌کند همبستگی زیادی دارند. کورنیا و همکاران (Cornia et al., ۲۰۱۸) با ترکیب ویژگی‌های یک شبکه کانولوشنی و یک سازوکار توجه بازگشتی، مدلی برای پیش‌بینی نقاط تثبیت نگاه در تصاویر ارائه دادند. وانگ و همکاران (Wang et al., ۲۰۱۸) یک مجموعه داده بزرگ برای پیش‌بینی برجستگی در ویدیو به نام DHF۱K منتشر کردند. نتایج آن‌ها نشان داد که مدل‌های قبلی که فقط اطلاعات زمانی را اضافه کرده بودند نسبت به مدل‌های تصویری ایستا بهبود کمی داشتند، اما مدل خود آن‌ها که یک شبکه LSTM را با یک سازوکار توجه ترکیب می‌کرد بهترین نتیجه را به دست آورد. این نتایج از استفاده این پژوهش از ویژگی‌های ResNet و سازوکار توجه پشتیبانی می‌کنند. البته در این پژوهش هیچ داده ردیابی نگاهی استفاده نمی‌شود و مدل فقط از طریق خطای پیش‌بینی حرکت یاد می‌گیرد که به کدام قسمت تصویر توجه کند.

۲-۷- جمع‌بندی و مقایسه پژوهش‌ها

مرور انجام‌شده در این فصل نشان می‌دهد که روش‌های کنترل و زنده‌سازی دوربین در بازی را می‌توان در سه دسته قرار داد. دسته اول روش‌های مبتنی بر قید و مدل‌های فیزیکی هستند که حرکت را کنترل یا هموار می‌کنند، اما چیزی به حرکت اضافه نمی‌کنند. دسته دوم روش‌های رویه‌ای مانند نویز پرلین و Camera Shake هستند که به حرکت جزئیات اضافه می‌کنند، اما این جزئیات به وضعیت بازی و به حرکت عمودی بازیکن وابسته نیستند و با دست تنظیم می‌شوند. دسته سوم روش‌های داده‌محور هستند که بیشتر روی سطح کلان حرکت دوربین تمرکز دارند؛ یعنی دوربین کجا قرار بگیرد و چه نمایی بگیرد.

جدول ۲-۲ مهم‌ترین کارهای مرور شده را از نظر ورودی، خروجی، منبع داده و ارتباط با این پژوهش مقایسه می‌کند.

جدول ۲-۲ - مقایسه پژوهش‌های مرتبط با پژوهش حاضر

پژوهش	ورودی	خروجی	منبع داده یا روش	ارتباط با این پژوهش
Christie et al. (۲۰۰۸)	قیدهای کادربندی	موقعیت و جهت دوربین	بهینه‌سازی (بدون داده)	کادربندی دقیق، بدون ویژگی‌های حرکت انسانی
Haigh-Hutchinson (۲۰۰۹)	موقعیت هدف	حرکت هموار دوربین	مدل فیزیکی	فقط هموارسازی، بدون جزئیات اضافه
Eiserloh (۲۰۱۶) Camera Shake آنریل	رویدادهای بازی	لرزش دوربین	نویز پرلین با تنظیم دستی	روش پایه مقایسه در فصل چهارم
Lécuyer et al. (۲۰۰۶) Terziman et al. (۲۰۱۳)	حالت حرکت کاراکتر	نوسان دوربین اول شخص	توابع ریاضی با تنظیم دستی	اثبات اثر مثبت نوسان بر تجربه کاربر
Huang et al. (۲۰۱۹)	اسکلت سوژه، تصویر، حرکت قبلی	حرکت پهباد	ویدیوی فیلم برداری حرفه‌ای	ترکیب تصویر و تاریخچه حرکت هدف: کادربندی
Jiang et al. (۲۰۲۰)	فیلم مرجع و صحنه سه بعدی	مسیر دوربین	کلیپ‌های سینمایی	انتقال سبک دوربین از داده به محیط مجازی
Xie et al. (۲۰۲۳)	صحنه سه بعدی	مسیر دوربین	یادگیری تقویتی با پاداش زیبایی شناختی	جمله نرمی برای جلوگیری از حرکت رباتیک
Karpenko et al. (۲۰۱۱) Grundmann et al. (۲۰۱۱)	ویدیو و ژيروسکوپ	مسیر هموار (حذف لرزش)	تثبیت ویدیو	همان تجزیه قصد و باقی مانده، ولی با هدف حذف
Holden et al. (۲۰۱۷)	فرمان بازیکن و زمین	حرکت کاراکتر	موشن کپچر	قصد از بازیکن، جزئیات از مدل
پژوهش حاضر	تصویر بازی، تاریخچه حرکت و قصد بازیکن	باقی مانده ارگانیک چرخش دوربین	ویدیو و ژيروسکوپ گوشی همراه	افزودن جزئیات حرکت انسانی به دوربین اول شخص به صورت زنده

همان‌طور که در جدول دیده می‌شود، هیچ‌یک از کارهای مرور شده به‌طور همزمان این سه ویژگی را ندارد: یادگیری جزئیات حرکت دوربین روی دست از داده واقعی، وابسته کردن این جزئیات به حرکت عمدی بازیکن و محتوای تصویر، و اجرای زنده در موتور بازی. نزدیک‌ترین کارها به این پژوهش از یک طرف روش‌های تثبیت ویدیو هستند که همین تجزیه را انجام می‌دهند اما باقی‌مانده را دور می‌ریزند، و از طرف دیگر کارهای لکوییر و ترزیمان که نشان داده‌اند نوسان دوربین برای کاربر مفید است اما آن را با دست طراحی کرده‌اند. این پایان‌نامه تلاش می‌کند این فاصله را پر کند. در فصل سوم، روش جمع‌آوری داده، معماری مدل و نحوه اتصال آن به آنریل انجین به تفصیل شرح داده می‌شود.

منابع فصل دوم

- Butterworth, S. (۱۹۳۰). On the theory of filter amplifiers. *Experimental Wireless and the Wireless Engineer*, ۷, ۵۳۶-۵۴۱.
- Chang, E., Kim, H. T., & Yoo, B. (۲۰۲۰). Virtual reality sickness: A review of causes and measurements. *International Journal of Human-Computer Interaction*, ۳۶(۱۷), ۱۶۵۸-۱۶۸۲.
- Cho, K., van Merriënboer, B., Gulcehre, C., Bahdanau, D., Bougares, F., Schwenk, H., & Bengio, Y. (۲۰۱۴). Learning phrase representations using RNN encoder-decoder for statistical machine translation. *Proceedings of EMNLP* ۲۰۱۴, ۱۷۲۴-۱۷۳۴.
- Christie, M., Olivier, P., & Normand, J.-M. (۲۰۰۸). Camera control in computer graphics. *Computer Graphics Forum*, ۲۷(۸), ۲۱۹۷-۲۲۱۸.
- Chung, J., Gulcehre, C., Cho, K., & Bengio, Y. (۲۰۱۴). Empirical evaluation of gated recurrent neural networks on sequence modeling. *arXiv preprint arXiv:1412.3555*.
- Cornia, M., Baraldi, L., Serra, G., & Cucchiara, R. (۲۰۱۸). Predicting human eye fixations via an LSTM-based saliency attentive model. *IEEE Transactions on Image Processing*, ۲۷(۱۰), ۵۱۴۲-۵۱۵۴.

- Deng, J., Dong, W., Socher, R., Li, L.-J., Li, K., & Fei-Fei, L. (2009). ImageNet: A large-scale hierarchical image database. *Proceedings of CVPR 2009*, 248-255.
- Eiserloh, S. (2016). *Math for game programmers: Juicing your cameras with math* [Conference presentation]. Game Developers Conference (GDC), San Francisco.
- Epic Games. (n.d.). *Camera shakes in Unreal Engine* (Unreal Engine 5 documentation). Retrieved September 29, 2026, from https://dev.epicgames.com/documentation/en-us/unreal-engine/camera-shakes-in-unreal-engine?application_version=5
- Gers, F. A., Schmidhuber, J., & Cummins, F. (2000). Learning to forget: Continual prediction with LSTM. *Neural Computation*, 12(10), 2451-2457.
- Grundmann, M., Kwatra, V., & Essa, I. (2011). Auto-directed video stabilization with robust L1 optimal camera paths. *Proceedings of CVPR 2011*, 225-232.
- Gustafsson, F. (1996). Determining the initial states in forward-backward filtering. *IEEE Transactions on Signal Processing*, 44(8), 988-992.
- Haigh-Hutchinson, M. (2009). *Real-time cameras: A guide for game designers and developers*. Morgan Kaufmann.
- Hammerla, N. Y., Halloran, S., & Plötz, T. (2016). Deep, convolutional, and recurrent models for human activity recognition using wearables. *Proceedings of IJCAI 2016*, 1533-1540.
- He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. *Proceedings of CVPR 2016*, 770-778.
- Hirasaki, E., Moore, S. T., Raphan, T., & Cohen, B. (1999). Effects of walking velocity on vertical head and body movements during locomotion. *Experimental Brain Research*, 124(2), 117-130.
- Hochreiter, S., & Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*, 9(8), 1735-1780.
- Holden, D., Komura, T., & Saito, J. (2017). Phase-functioned neural networks for character control. *ACM Transactions on Graphics*, 36(8), Article 42.
- Huang, C., Lin, C.-E., Yang, Z., Kong, Y., Chen, P., Yang, X., & Cheng, K.-T. (2019). Learning to film from professional human motion videos. *Proceedings of CVPR 2019*, 4244-4253.

- ITU-T. (2023). *Recommendation P.910: Subjective video quality assessment methods for multimedia applications*. International Telecommunication Union.
- Jennett, C., Cox, A. L., Cairns, P., Dhoparee, S., Epps, A., Tijs, T., & Walton, A. (2008). Measuring and defining the experience of immersion in games. *International Journal of Human-Computer Studies*, 66(9), 641-661.
- Jiang, H., Wang, B., Wang, X., Christie, M., & Chen, B. (2020). Example-driven virtual cinematography by learning camera behaviors. *ACM Transactions on Graphics*, 39(2).
<https://doi.org/10.1145/3386069/3392427>
- Karpenko, A., Jacobs, D., Baek, J., & Levoy, M. (2011). *Digital video stabilization and rolling shutter correction using gyroscopes* (Stanford Tech Report CTSR 2011-03). Stanford University.
- Kennedy, R. S., Lane, N. E., Berbaum, K. S., & Lilienthal, M. G. (1993). Simulator sickness questionnaire: An enhanced method for quantifying simulator sickness. *The International Journal of Aviation Psychology*, 3(3), 203-220.
- LaViola, J. J., Jr. (2000). A discussion of cybersickness in virtual environments. *ACM SIGCHI Bulletin*, 32(1), 47-56.
- Lécuyer, A., Burkhardt, J.-M., Henaff, J.-M., & Donikian, S. (2006). Camera motions improve the sensation of walking in virtual environments. *Proceedings of IEEE Virtual Reality* 2006, 11-18.
- McAuley, J. H., & Marsden, C. D. (2000). Physiological and pathological tremors and rhythmic central motor control. *Brain*, 123(8), 1040-1067.
- Ordóñez, F. J., & Roggen, D. (2016). Deep convolutional and LSTM recurrent neural networks for multimodal wearable activity recognition. *Sensors*, 16(1), 110.
- Perlin, K. (1985). An image synthesizer. *ACM SIGGRAPH Computer Graphics*, 19(3), 289-296.
- Reason, J. T., & Brand, J. J. (1975). *Motion sickness*. Academic Press.
- Riccio, G. E., & Stoffregen, T. A. (1991). An ecological theory of motion sickness and postural instability. *Ecological Psychology*, 3(3), 190-240.
- Stoffregen, T. A., Faugloire, E., Yoshida, K., Flanagan, M. B., & Merhi, O. (2008). Motion sickness and postural sway in console video games. *Human Factors*, 50(2), 322-331.

- Terziman, L., Marchal, M., Multon, F., Arnaldi, B., & Lé cuyer, A. (2013). Personified and multistate camera motions for first-person navigation in desktop virtual reality. *IEEE Transactions on Visualization and Computer Graphics*, 19(8), 652-661.
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is all you need. *Advances in Neural Information Processing Systems* 30, 5998-6008.
- Wang, W., Shen, J., Guo, F., Cheng, M.-M., & Borji, A. (2018). Revisiting video saliency: A large-scale benchmark and a new model. *Proceedings of CVPR* 2018, 2892-2903.
- Winter, D. A. (2009). *Biomechanics and motor control of human movement* (2th ed.). Wiley.
- Xie, D., Hu, P., Sun, X., Pirk, S., Zhang, J., Mech, R., & Kaufman, A. E. (2023). GAIT: Generating aesthetic indoor tours with deep reinforcement learning. *Proceedings of ICCV* 2023, 7209-7219.