

فصل سوم: روش تحقیق

۳-۱- مقدمه

در این فصل روش انجام پژوهش، از جمع‌آوری داده تا اجرای مدل در بازی و طراحی ارزیابی، شرح داده می‌شود. همان‌طور که در فصل اول توضیح داده شد، ایده اصلی این پژوهش این است که حرکت دوربین اول‌شخص به دو بخش تقسیم شود: قصد بازیکن که از ماوس به دست می‌آید و دست‌نخورده باقی می‌ماند، و یک لایه ارگانیسم که مدل آن را از روی حرکت واقعی دوربین روی دست یاد گرفته است و به قصد اضافه می‌کند. برای رسیدن به این هدف چهار کار باید انجام شود: ضبط داده حرکت واقعی، جدا کردن قصد از حرکت ارگانیسم در این داده، آموزش مدلی که حرکت ارگانیسم را پیش‌بینی کند، و اجرای زنده این مدل در کنار آنریبل انجین با تأخیر کم.

ترتیب مطالب فصل به این صورت است. در بخش ۳-۲ نمای کلی سیستم ارائه می‌شود. بخش ۳-۳ به روش جمع‌آوری داده و بخش ۳-۴ به پیش‌پردازش آن اختصاص دارد. معماری مدل در بخش ۳-۵ و تابع هزینه و روش آموزش در بخش ۳-۶ آمده است. بخش ۳-۷ پیاده‌سازی سمت آنریبل و ارتباط OSC را توضیح می‌دهد و بخش ۳-۸ روش اندازه‌گیری تأخیر را. در بخش ۳-۹ طراحی ارزیابی، شامل معیارهای عینی و آزمون کاربری، شرح داده می‌شود و بخش ۳-۱۰ جمع‌بندی فصل است.

در این فصل هر جا که مقداری هنوز قطعی نشده و به نتیجه مرحله ضبط داده بستگی دارد، با علامت [] مشخص شده است.


۳-۲- نمای کلی سیستم

سیستم پیشنهادی دو مرحله جدا دارد که در شکل ۳-۱ نشان داده شده‌اند. در مرحله آفلاین، ویدیو و داده ژيروسکوپ با گوشی همراه ضبط می‌شود، چرخش دوربین در هر فریم محاسبه می‌شود، این چرخش به دو بخش قصد و باقی‌مانده

تقسیم می‌شود و سپس مدل با این داده آموزش می‌بیند. خروجی این مرحله وزن‌های مدل و پارامترهای نرمال‌سازی داده است.

در مرحله زنده، آنریل انجین در هر فریم تغییر زاویه کنترل بازیکن (قصد) و سرعت حرکت کاراکتر را با یک پیام OSC به یک برنامه پایتون می‌فرستد. برنامه پایتون این مقادیر را در گام‌های ۳۰ هرتز جمع می‌کند، آخرین تصویر پنجره بازی را می‌گیرد، با مدل باقی‌مانده گام بعد را پیش‌بینی می‌کند و آن را با یک پیام OSC دیگر به آنریل برمی‌گرداند. آنریل این باقی‌مانده را روی دوربین اعمال می‌کند، بدون اینکه جهت کنترل بازیکن تغییر کند.

دلیل اجرای مدل در یک برنامه جدا این است که آموزش و اجرای مدل با کتابخانه PyTorch (Paszke et al, ۲۰۱۹) انجام می‌شود و انتقال مستقیم آن به داخل موتور بازی کار جداگانه و زمان‌بری است. ارتباط دو برنامه از طریق شبکه محلی انجام می‌شود و آنریل منتظر جواب پایتون نمی‌ماند؛ اگر در یک فریم پیامی نرسیده باشد، دوربین بدون لایه ارگانیک به کار خود ادامه می‌دهد. به این ترتیب کند شدن یا متوقف شدن برنامه پایتون هیچ‌وقت باعث توقف بازی نمی‌شود.



شکل ۳-۱- نمای کلی سیستم پیشنهادی در دو مرحله آفلاین و زنده

۳-۳- جمع‌آوری داده

۳-۳-۱- ضبط ویدیو و ژيروسکوپ با گوشی همراه

برای ضبط داده از برنامه متن‌باز OpenCamera Sensors روی یک گوشی اندرویدی استفاده شده است. این برنامه نسخه تغییر یافته برنامه Open Camera است و همراه با ویدیو، خروجی ژيروسکوپ و شتاب‌سنج و زمان ثبت هر فریم را با یک ساعت مشترک ذخیره می‌کند (Akhmetyanov et al., ۲۰۲۱). وجود ساعت مشترک مهم‌ترین دلیل انتخاب این برنامه است، چون همان‌طور که در فصل دوم گفته شد، برای به دست آوردن چرخش دورین در هر فریم باید داده ژيروسکوپ دقیقاً با فریم‌ها هم‌زمان باشد. تنظیمات ضبط در جدول ۳-۱ آمده است.

جدول ۳-۱- تنظیمات ضبط در برنامه OpenCamera Sensors

تنظیم	مقدار	دلیل
رابط دورین	Camera۲ API	لازم برای ثبت زمان هر فریم
ضبط هم‌زمان حسگرها	فعال (ژيروسکوپ و شتاب‌سنج)	داده اصلی برای محاسبه چرخش
نرخ فریم	۳۰ فریم بر ثانیه	برابر با نرخ کار مدل
وضوح	۷۲۰p	کافی برای ورودی ۲۲۴ در ۲۲۴ مدل حجم کمتر
لرزش گیر نرم‌افزاری و نوری	غیرفعال	لرزش گیر همان حرکتی را حذف می‌کند که هدف یادگیری است
نرخ نمونه‌برداری ژيروسکوپ	حدود ۵۰۰ هرتز	بیشترین نرخ که گوشی در اختیار می‌گذارد

خروجی هر ضبط شامل یک فایل ویدیو، دو فایل CSV برای ژيروسکوپ و شتاب‌سنج که در هر سطر مقدار سه محور و زمان ثبت بر حسب نانوثانیه را دارند، و یک فایل CSV شامل زمان ثبت هر فریم است.

۳-۲-۳- محیط و سناریوهای ضبط

همه ضبط‌ها در یک محیط انجام می‌شود: فضای اداری یک استودیوی انیمیشن. انتخاب یک محیط واحد دو دلیل دارد. اول اینکه هدف این پژوهش یادگیری ویژگی‌های حرکت دست انسان است و نه تنوع محیط، و ثابت نگه داشتن محیط کمک می‌کند تفاوت‌ها بین داده‌ها بیشتر به نوع حرکت مربوط باشد. دوم اینکه یک محیط مشابه در آنریل ساخته شده است، و به این ترتیب فاصله ظاهری بین تصویرهای آموزش و تصویرهای بازی کمتر می‌شود (بخش ۳-۳-۳).

سناریوهای ضبط طوری انتخاب شده‌اند که حالت‌های رایج حرکت در یک بازی اول‌شخص را پوشش دهند. در همه سناریوها شرکت‌کننده گوشی را به صورت افقی و تقریباً در ارتفاع چشم نگه می‌دارد، طوری که انگار از دید خودش فیلم می‌گیرد. فهرست سناریوها در جدول ۳-۲ آمده است.

جدول ۳-۲- سناریوهای ضبط داده

سناریو	شرح	هدف
ایستاده (idle)	ایستادن و نگاه کردن آرام به اطراف	لرزش دست در حالت سکون
راه رفتن (walk)	راه رفتن با سرعت عادی در راهروها	حرکت ناشی از گام‌ها
راه رفتن تند (fastwalk)	راه رفتن با سرعت بیشتر، بدون دویدن	افزایش دامنه حرکت گام
دنبال کردن (track)	دنبال کردن یکی از همکاران که در حال راه رفتن است	حرکت عمدی پیوسته همراه با تصویر

سناریو	شرح	هدف
چرخش ناگهانی (turn)	چرخیدن سریع به سمت یک نقطه و توقف	حرکات اصلاحی بعد از چرخش تند
پله (stairs، اختیاری)	بالا و پایین رفتن از پله	حرکت عمودی بیشتر

هر فایل بر اساس الگوی «شماره شرکت کننده_محیط_سناریو_شماره تکرار» نام گذاری می شود؛ مثلاً ۰۱_office_walk_p01. شماره شرکت کننده در ابتدای نام قرار دارد تا بتوان داده را بر اساس افراد تقسیم کرد (بخش ۳-۴-۶). داده از [] شرکت کننده و در مجموع حدود [] دقیقه ضبط شده است.

پیش از ضبط، از مدیر استودیو اجازه گرفته شده و به همکارانی که در تصویر دیده می شوند اطلاع داده شده است. در طول ضبط از فیلم گرفتن از نمایشگرها، استوری بوردها و کارهای منتشر نشده استودیو خودداری شده است. این ویدیوها فقط برای آموزش مدل استفاده می شوند و منتشر نمی شوند.

۳-۳-۳- محیط آنریل

برای اجرای زنده و ساخت کلیپ های آزمون کاربری، یک پروژه آنریل انجین ۵/۴ با زبان C++ و بر پایه قالب اول شخص (First Person) ساخته شده است. در این پروژه یک محیط اداری مشابه محیط ضبط، همراه با چند کاراکتر متحرک، طراحی شده است. کاراکترهای متحرک به این دلیل اضافه شده اند که شرایط سناریوی «دنبال کردن» در بازی هم وجود داشته باشد. در سمت آنریل هیچ داده ای برای آموزش مدل جمع نمی شود؛ نقش آنریل فراهم کردن قصد بازیکن و تصویر صحنه در زمان اجرا است.

باید توجه داشت که مدل با تصویرهای واقعی آموزش می بیند ولی در بازی تصویرهای رندر شده را می بیند. این تفاوت دامنه (domain gap) یکی از محدودیت های این پژوهش است. دو تصمیم برای کم کردن اثر آن گرفته شده است:

شبکه تصویری با وزن‌های ثابت استفاده می‌شود که ویژگی‌های عمومی و کمتر وابسته به جزئیات بافت را استخراج می‌کند (بخش ۳-۵-۱)، و محیط بازی از نظر چیدمان و مقیاس به محیط ضبط نزدیک است.

۳-۴- پیش‌پردازش داده

پیش‌پردازش هر ضبط با یک اسکرپت پایتون انجام می‌شود که از کتابخانه‌های SciPy (Virtanen et al., ۲۰۲۰) برای طراحی و اعمال فیلترها و OpenCV (Bradski, ۲۰۰۰) برای کار با ویدیو استفاده می‌کند. خروجی اسکرپت برای هر ضبط یک پوشه شامل فریم‌های تغییر اندازه‌یافته، یک فایل حرکت و یک فایل اطلاعات است. مراحل آن در ادامه آمده است.

۳-۴-۱- همگام‌سازی فریم‌ها و ژيروسکوپ

با اینکه OpenCamera Sensors زمان فریم‌ها و حسگرها را با یک ساعت ثبت می‌کند، زمانی که برای هر فریم ثبت می‌شود لزوماً با لحظه واقعی نوردهی آن فریم یکی نیست. کارپنکو و همکاران (Karpenko et al., ۲۰۱۱) هم به وجود چنین اختلافی اشاره کرده و آن را با یک ضبط کالیبراسیون تخمین زده‌اند. در این پژوهش این اختلاف با مقایسه حرکت دیده‌شده در تصویر و حرکت اندازه‌گیری‌شده با ژيروسکوپ تخمین زده شده است.

برای این کار، ابتدا جریان نوری متراکم بین هر دو فریم متوالی با روش فارنبک (Farneback, ۲۰۰۳) محاسبه شد و میانه جابه‌جایی افقی و عمودی پیکسل‌ها به عنوان حرکت کلی تصویر در نظر گرفته شد. سپس چرخش دورین از روی ژيروسکوپ، به ازای اختلاف‌های زمانی مختلف δ بین ۶۰- تا ۶۰+ میلی ثانیه، محاسبه شد و اختلافی انتخاب شد که بیشترین همبستگی را بین این دو ایجاد می‌کند:

$$(۳-۱) \quad \delta^* = \arg \max_{\delta} [\rho(\Delta\theta^{yaw}(\delta), f_x) + \rho(\Delta\theta^{pitch}(\delta), -f_y)]$$

که در آن f_x و f_y حرکت افقی و عمودی تصویر و ρ ضریب همبستگی پیرسون است. علامت منفی در جمله دوم به این دلیل است که با بالا رفتن دوربین، تصویر به سمت پایین حرکت می کند. روی ضبط آزمایشی، بهترین اختلاف ۲۱ میلی ثانیه به دست آمد و در این اختلاف، همبستگی بین حرکت تصویر و ژيروسکوپ برای چرخش افقی ۰/۷۶ و برای چرخش عمودی ۰/۷۵ بود. این همبستگی با توجه به اینکه جریان نوری به حرکت اشیای صحنه و جابه جایی دوربین هم حساس است، نشان می دهد داده به درستی همگام شده است. این اختلاف برای همه ضبط های یک گوشی ثابت در نظر گرفته می شود و فقط در صورت تعویض گوشی دوباره اندازه گیری خواهد شد. باید توجه داشت که جریان نوری فقط برای همین بررسی استفاده می شود و در آموزش مدل نقشی ندارد.

۳-۴-۲- محاسبه چرخش در هر فریم

همان طور که در بخش ۲-۲-۲ توضیح داده شد، ژيروسکوپ سرعت زاویه ای را در دستگاه مختصات گوشی اندازه می گیرد. برای به دست آوردن چرخش افقی حول محور قائم، ابتدا جهت گرانش از خروجی شتاب سنج تخمین زده می شود. برای این کار خروجی شتاب سنج با یک فیلتر باترورث مرتبه دو با فرکانس قطع ۰/۵ هرتز و به صورت رفت و برگشت هموار می شود تا شتاب های ناشی از حرکت حذف شوند و فقط جهت گرانش باقی بماند. اگر u بردار یکه رو به بالا و ω بردار سرعت زاویه ای باشد، سرعت چرخش افقی و عمودی به صورت زیر محاسبه می شود:

$$(۳-۲) \quad \omega_{yaw} = -\omega \cdot u, \quad \omega_{pitch} = -\omega_y$$

که در آن ω_y سرعت زاویه ای حول محور افقی گوشی در حالت افقی است. علامت ها طوری انتخاب شده اند که چرخش به راست و چرخش رو به بالا مثبت باشند، که با قرارداد آنریل یکسان است. سپس این سرعت ها بین زمان ثبت دو فریم متوالی، با در نظر گرفتن اختلاف زمانی δ ، انتگرال گیری می شوند (رابطه ۲-۱) و چرخش هر فریم بر حسب درجه به دست می آید.

۳-۴-۳- جدا کردن قصد و باقی مانده

چرخش هر فریم مطابق روش بخش ۲-۲-۳ به دو بخش تقسیم می شود. قصد با یک فیلتر پایین گذر باترورت مرتبه دو با فرکانس قطع ۱ هرتز که به صورت رفت و برگشت اعمال می شود به دست می آید، و باقی مانده تفاضل چرخش کل و قصد است (رابطه های ۲-۲ و ۳-۲). این کار برای هر دو محور افقی و عمودی به طور جداگانه انجام می شود. در ضبط آزمایشی، انحراف معیار باقی مانده ۰/۴۵ درجه بر فریم برای چرخش افقی و ۰/۳۱ درجه بر فریم برای چرخش عمودی بود.

۳-۴-۴- برچسب سرعت حرکت

مدل برای تشخیص حالت حرکت (ایستاده یا در حال راه رفتن) به یک ورودی سرعت نیاز دارد. در بازی سرعت کاراکتر مستقیماً در دسترس است، اما در داده گویی باید تخمین زده شود. برای این کار از شدت نوسان شتاب سنج استفاده شده است: انحراف معیار اندازه بردار شتاب در یک پنجره یک ثانیه ای محاسبه می شود. اگر این مقدار کمتر از ۰/۶ متر بر مجذور ثانیه باشد، سرعت صفر (ایستاده)، اگر بین ۰/۶ و ۳ باشد، سرعت ۱/۴ متر بر ثانیه (راه رفتن)، و در غیر این صورت ۳ متر بر ثانیه در نظر گرفته می شود. عدد ۱/۴ متر بر ثانیه نزدیک به سرعت معمول راه رفتن انسان است. در ضبط آزمایشی ۳۴ درصد فریم ها «ایستاده» و ۶۶ درصد «راه رفتن» برچسب خوردند. این آستانه ها باید پس از ضبط سناریوی راه رفتن تند دوباره تنظیم شوند [۱].

در آنریل، سرعت کاراکتر بر حسب متر بر ثانیه ارسال می شود. برای اینکه ورودی مدل در دو دامنه یکسان باشد، سرعت بیشینه راه رفتن کاراکتر نزدیک به ۱/۴ متر بر ثانیه تنظیم می شود [۱].

۳-۴-۵- ساخت نمونه های آموزشی

فریم های ویدیو با اندازه ۲۲۴ در ۲۲۴ پیکسل استخراج و به صورت فایل تصویری ذخیره می شوند تا در زمان آموزش نیازی به رمزگشایی ویدیو نباشد. در کنار آن، برای هر فریم یک بردار حرکت پنج تایی ساخته می شود:

$$(3-3) \quad m_t = [i_t^{yaw}, i_t^{pitch}, r_t^{yaw}, r_t^{pitch}, v_t]$$

که به ترتیب قصد افقی و عمودی، باقی مانده افقی و عمودی و سرعت هستند. هر نمونه آموزشی برای گام t شامل دو گام متوالی است:

$$(3-4) \quad X_t = (I_t, I_{t+1}, M_{t-T:t-1}, M_{t-T+1:t}), \quad Y_t = (r_t, r_{t+1})$$

یعنی فریم های t و $t+1$ ، تاریخچه ده تایی بردار حرکت که به هر یک از این دو فریم ختم می شود، و باقی مانده همان دو فریم به عنوان هدف. طول تاریخچه ($T = 10$ گام، یعنی یک سوم ثانیه) طوری انتخاب شده است که بیش از نیم چرخه حرکت گام (حدود دو هرتز) را پوشش دهد و در عین حال مدل کوچک و سریع بماند. دلیل استفاده از دو گام متوالی در هر نمونه این است که جمله نرمی در تابع هزینه (بخش 3-6) به دو پیش بینی پشت سر هم از یک دنباله نیاز دارد. اگر این دو پیش بینی از نمونه های جداگانه گرفته شوند، به دلیل درهم ریختن ترتیب نمونه ها در آموزش، دیگر به هم مربوط نخواهند بود.

یک نکته در ساخت تاریخچه این است که در زمان آموزش، باقی مانده واقعی گام های قبل در تاریخچه قرار می گیرد، اما در زمان اجرا باقی مانده واقعی وجود ندارد و به جای آن پیش بینی خود مدل در گام قبل استفاده می شود. این روش که به «آموزش با معلم» (teacher forcing) شناخته می شود ساده است، اما ممکن است باعث شود خطای مدل در اجرای زنده جمع شود. اثر این موضوع در فصل چهارم بررسی می شود.

3-4-6- تقسیم داده و نرمال سازی

داده بر اساس افراد تقسیم می شود و نه بر اساس فریم ها. همه ضبط های یک شرکت کننده فقط در یکی از مجموعه های آموزش، اعتبارسنجی یا آزمون قرار می گیرند. این کار به این دلیل لازم است که فریم های متوالی یک ضبط بسیار به هم شبیه اند و اگر به صورت تصادفی تقسیم شوند، ارزیابی مدل بیش از حد خوش بینانه خواهد بود. علاوه بر این، تقسیم بر اساس افراد نشان می دهد که آیا مدل ویژگی های کلی حرکت دست انسان را یاد گرفته یا فقط سبک حرکت

افراد داخل مجموعه آموزش را. در حال حاضر شرکت کننده $p=0.5$ برای اعتبارسنجی و $p=0.6$ برای آزمون در نظر گرفته شده اند []. برای آزمایش های اولیه که فقط یک ضبط وجود داشت، همان ضبط بر اساس زمان به سه بخش ۷۰، ۱۵ و ۱۵ درصدی تقسیم شد و بین بخش ها یک فاصله یک ثانیه ای در نظر گرفته شد.


هر یک از پنج ویژگی حرکت و دو مؤلفه هدف با میانگین و انحراف معیار مجموعه آموزش نرمال می شوند:

$$(3-5) \quad \tilde{m} = \frac{m - \mu_{train}}{\sigma_{train}}$$

این پارامترها همراه با وزن های مدل ذخیره می شوند تا در زمان اجرا دقیقاً همان تبدیل روی ورودی ها و معکوس آن روی خروجی اعمال شود. تصویرها هم با میانگین و انحراف معیار مجموعه داده ImageNet نرمال می شوند، چون شبکه تصویری با همین نرمال سازی آموزش دیده است.

۳-۵- معماری مدل

ساختار کلی مدل در شکل ۳-۲ نشان داده شده است. مدل دو ورودی دارد: فریم بازی و تاریخچه حرکت. هر ورودی در یک شاخه جداگانه پردازش می شود و دو شاخه در یک لایه توجه متقاطع با هم ترکیب می شوند. خروجی مدل باقی مانده چرخش افقی و عمودی در گام بعد است. مبانی نظری اجزای مدل در بخش ۲-۴ آمده است و در اینجا فقط جزئیات پیاده سازی شرح داده می شود.



شکل ۳-۲- معماری مدل پیشنهادی (رنگ آبی: لایه‌های آموزش‌پذیر)

۳-۵-۱- شاخه تصویر

در این شاخه از شبکه ResNet-18 (He et al., ۲۰۱۶) که روی ImageNet آموزش دیده است استفاده می‌شود. لایه میانگین‌گیری سراسری و لایه طبقه‌بندی آخر شبکه حذف شده‌اند، بنابراین خروجی شبکه برای یک تصویر ۲۲۴ در ۲۲۴ یک نقشه ویژگی ۷ در ۷ با ۵۱۲ کانال است. هر یک از ۴۹ خانه این نقشه به یک ناحیه از تصویر مربوط است و به‌عنوان یک «نشانه» در نظر گرفته می‌شود. دلیل حذف میانگین‌گیری سراسری این است که لایه توجه بتواند بین نواحی مختلف تصویر تفاوت قائل شود.

همه وزن‌های ResNet در طول آموزش ثابت هستند و لایه‌های نرمال‌سازی دسته‌ای آن هم همیشه در حالت ارزیابی قرار دارند تا آماره‌هایشان با داده‌های کم این پژوهش تغییر نکند. هر نشانه با یک لایه خطی از ۵۱۲ به ۱۲۸ بعد نگاشت می‌شود، یک جاسازی مکانی آموزش‌پذیر به آن اضافه می‌شود و در نهایت نرمال‌سازی لایه‌ای (Ba et al., ۲۰۱۶)

روی آن اعمال می‌شود. جاسازی مکانی به همان شکلی است که در ترنسفورمرهای تصویری استفاده می‌شود (Dosovitskiy et al., ۲۰۲۱) و به مدل امکان می‌دهد جای هر نشانه در تصویر را بداند؛ بدون آن، لایه توجه نمی‌تواند مثلاً بین مرکز تصویر و گوشه آن تفاوتی قائل شود.

۳-۵-۲- شاخه حرکت

تاریخچه حرکت، یعنی ماتریسی با ۱۰ سطر و ۵ ستون، به یک لایه GRU با حالت پنهان ۶۴ بعدی داده می‌شود. حالت پنهان آخرین گام به عنوان خلاصه حرکت اخیر در نظر گرفته می‌شود و با یک لایه خطی به ۱۲۸ بعد نگاشت شده و نرمال می‌شود. این بردار که آن را q می‌نامیم، پرسش لایه توجه متقاطع است.

۳-۵-۳- لایه توجه متقاطع و خروجی

لایه توجه متقاطع یک توجه چندسر با ۴ سر و بعد ۱۲۸ است (رابطه‌های ۲-۱۴ تا ۲-۱۶). پرسش آن بردار حرکت q و کلید و مقدار آن ۴۹ نشانه تصویری هستند. خروجی توجه با یک اتصال باقی‌مانده با خود پرسش جمع و سپس نرمال می‌شود:

$$(۳-۶) \quad c = \text{LayerNorm}(q + \text{MultiHead}(q, K, V))$$

این اتصال باقی‌مانده باعث می‌شود اطلاعات حرکت حتی در صورتی که توجه اطلاعات مفیدی از تصویر به دست نیامد، به طور کامل به لایه‌های بعد برسد. در نهایت بردار زمینه C و بردار حرکت q کنار هم قرار می‌گیرند و از یک پرسپترون دولایه با ۱۲۸ نورون پنهان و تابع فعال‌ساز (Hendrycks & Gimpel, ۲۰۱۶) GELU عبور می‌کنند تا دو خروجی، یعنی باقی‌مانده نرمال‌شده چرخش افقی و عمودی، تولید شود. وزن‌های توجه که برای هر فریم ۴۹ عدد هستند (میانگین روی ۴ سر) ذخیره می‌شوند تا در فصل چهارم بررسی شود مدل به کدام نواحی تصویر توجه می‌کند.

تعداد پارامترهای هر بخش در جدول ۳-۳ آمده است. همان‌طور که دیده می‌شود، بیش از ۹۸ درصد پارامترهای مدل مربوط به ResNet است که ثابت است، و مدل فقط حدود ۱۹۴ هزار پارامتر آموزش‌پذیر دارد. این عدد با توجه به حجم محدود داده مناسب است.

جدول ۳-۳- ابعاد و تعداد پارامترهای بخش‌های مدل

بخش	ابعاد ورودی ← خروجی	تعداد پارامتر	آموزش‌پذیر
ResNet-۱۸ (بدون لایه‌های آخر)	$3 \times 224 \times 224 \leftarrow$ $512 \times 7 \times 7$	۱۱'۱۷۶'۵۱۲	خیر
نگاشت نشانه‌ها، جاسازی مکانی و نرمال‌سازی	$512 \times 49 \leftarrow 128 \times 49$	۷۲'۱۹۲	بله
GRU	$5 \times 10 \leftarrow 64$	۱۳'۶۳۲	بله
نگاشت حرکت و نرمال‌سازی	$64 \leftarrow 128$	۸'۵۷۶	بله
توجه متقاطع (۴ سر) و نرمال‌سازی	$128 \leftarrow 128 \times 49$ و 128	۶۶'۳۰۴	بله
پرسترون خروجی	$256 \leftarrow 128 \leftarrow 2$	۳۳'۱۵۴	بله
مجموع		۱۱'۳۷۰'۳۷۰	۱۹۳'۸۵۸

۳-۵-۴- نسخه‌های مقایسه‌ای مدل

برای بررسی سهم هر بخش از مدل (سؤال دوم پژوهش)، دو نسخه ساده‌تر هم با همان داده و همان تنظیمات آموزش داده می‌شوند. در نسخه «فقط حرکت»، شاخه تصویر و لایه توجه حذف می‌شوند و خروجی فقط از بردار حرکت q به دست می‌آید. در نسخه «بدون توجه»، شاخه تصویر وجود دارد اما به جای توجه متقاطع، میانگین ساده‌ی ۴۹ نشانه

با بردار حرکت ترکیب می‌شود. مقایسه مدل کامل با این دو نسخه نشان می‌دهد که آیا تصویر به پیش‌بینی کمک می‌کند و آیا توجه متقاطع نسبت به یک ترکیب ساده برتری دارد.

۳-۶- تابع هزینه و روش آموزش

۳-۶-۱- تابع هزینه

تابع هزینه از سه جمله تشکیل شده است:

$$(۳-۷) \quad L = \alpha L_{pos} + \beta L_{dir} + \gamma L_{smooth}$$

همه جمله‌ها روی مقادیر نرمال شده محاسبه می‌شوند. اگر $\hat{y}_{i,k}$ پیش‌بینی مدل و $y_{i,k}$ مقدار واقعی باقی‌مانده برای نمونه i از یک دسته B تایی و گام $k \in \{1, 2\}$ باشد، جمله اول میانگین مربعات خطا است:

$$(۳-۸) \quad L_{pos} = \frac{1}{\epsilon_B} \sum_{i=1}^B \sum_{k=1}^2 \|\hat{y}_{i,k} - y_{i,k}\|^2$$

این جمله مدل را وادار می‌کند باقی‌مانده را با کمترین خطا پیش‌بینی کند. اما میانگین مربعات خطا یک مشکل شناخته شده دارد: وقتی آینده قطعی نیست، بهترین جواب از نظر این معیار میانگین حالت‌های ممکن است. در مورد این پژوهش، چون حرکت ارگانیک تا حدی تصادفی است، مدلی که فقط با این جمله آموزش ببیند تمایل دارد خروجی‌های کوچک و نزدیک به صفر تولید کند. دو جمله دیگر برای کم کردن این مشکل اضافه شده‌اند.

جمله دوم جهت حرکت را جدا از اندازه آن بررسی می‌کند. این جمله بر اساس شباهت کسینوسی بین بردار پیش‌بینی و بردار واقعی تعریف می‌شود:

$$(۳-۹) \quad L_{dir} = \frac{1}{|S|} \sum_{(i,k) \in S} (1 - \cos(\hat{y}_{i,k}, y_{i,k}))$$

که در آن S مجموعه جفت‌هایی است که اندازه بردار واقعی در آن‌ها از آستانه $\tau = 0.1$ (در واحد نرمال شده) بیشتر است، و $|S|$ تعداد این جفت‌ها است. دلیل این شرط این است که وقتی باقی‌مانده واقعی تقریباً صفر است، جهت آن عملاً نویز است و جریمه کردن مدل برای اختلاف جهت در این نمونه‌ها معنایی ندارد. چون شباهت کسینوسی به

اندازه بردار بستگی ندارد، این جمله مدل را تشویق می‌کند جهت حرکت را درست پیش‌بینی کند، حتی اگر اندازه آن را دقیق نداند.

جمله سوم به تغییر باقی مانده بین دو گام متوالی مربوط است:

$$(3-10) \quad L_{smooth} = \frac{1}{\gamma_B} \sum_{i=1}^B \|(\hat{y}_{i,2} - \hat{y}_{i,1}) - (y_{i,2} - y_{i,1})\|^2$$

این جمله تغییر پیش‌بینی بین دو گام را با تغییر واقعی مقایسه می‌کند. باید توجه داشت که این جمله با یک جمله هموارسازی معمولی که تفاضل دو پیش‌بینی را به سمت صفر می‌برد تفاوت دارد. هموارسازی معمولی خروجی را کند می‌کند و دقیقاً همان تغییرات سریعی را حذف می‌کند که هدف این پژوهش بازسازی آنهاست. در مقابل، جمله رابطه ۳-۱۰ فقط تغییراتی را جریمه می‌کند که در داده واقعی وجود ندارند، یعنی پرش‌های غیرطبیعی بین دو گام، و تغییرات واقعی را حفظ می‌کند.

ضرایب جمله‌ها $\alpha = 1$ ، $\beta = 0.6$ و $\gamma = 0.4$ انتخاب شده‌اند. جمله میانگین مربعات خطا جمله اصلی است و دو جمله دیگر نقش کمکی دارند. این ضرایب بر اساس آزمایش‌های اولیه تنظیم شده‌اند و اثر آنها در فصل چهارم بررسی خواهد شد [۱].

۳-۶-۲- تنظیمات آموزش

مدل با بهینه‌ساز Adam (Kingma & Ba, ۲۰۱۵) با نرخ یادگیری 0.0003 و سایر پارامترها با مقادیر پیش‌فرض آموزش داده می‌شود. برای جلوگیری از گرادیان‌های خیلی بزرگ، نرم گرادیان به 1 محدود می‌شود. در پایان هر دوره، مدل روی مجموعه اعتبارسنجی ارزیابی می‌شود و وزن‌های دوره‌ای که کمترین هزینه اعتبارسنجی را دارد ذخیره می‌شود. این کار در عمل نوعی توقف زود هنگام است؛ در آزمایش‌های اولیه روی یک ضبط، مدل پس از حدود شش دوره شروع به بیش‌برازش کرد. خلاصه تنظیمات در جدول ۳-۴ آمده است.

جدول ۳-۴- تنظیمات آموزش مدل

پارامتر	مقدار
اندازه دسته	۳۲ نمونه (۶۴ پیش‌بینی)
بهینه‌ساز	Adam، نرخ یادگیری ۰/۰۰۰۳
تعداد دوره	۱۵، با ذخیره بهترین دوره روی اعتبارسنجی
محدودیت نرم گرادیان	۱/۰
Dropout در لایه توجه	۰/۱
ضرایب تابع هزینه	$\alpha = ۱$ ، $\beta = ۰/۶$ ، $\gamma = ۰/۴$ ، $\tau = ۰/۱$
طول تاریخچه	۱۰ گام (۳۰ هرتز)
سخت‌افزار	کارت گرافیک NVIDIA RTX ۵۰۸۰
مقدار اولیه تصادفی	۰

۳-۷- پیاده‌سازی در آنریل و ارتباط زنده

۳-۷-۱- کامپوننت دوربین ارگانیک

در سمت آنریل، یک کامپوننت C++ به نام OrganicCameraComponent پیاده‌سازی و به کاراکتر اول شخص اضافه شده است. در قالب پیش‌فرض آنریل، دوربین مستقیماً جهت کنترل بازیکن را دنبال می‌کند. در این پروژه این رفتار غیرفعال شده و کامپوننت خودش در هر فریم جهت دوربین را برابر با جهت کنترل به‌علاوه یک انحراف ارگانیک O_n قرار می‌دهد. به این ترتیب انحراف فقط روی تصویر اثر دارد و جهت کنترل بازیکن، که برای نشانه‌گیری و حرکت استفاده می‌شود، دست‌نخورده باقی می‌ماند. این کامپوننت پس از اعمال ورودی ماوس و پیش از خوانده شدن تصویر دوربین اجرا می‌شود.

کامپوننت چهار حالت دارد که با کلیدهای ۱ تا ۴ قابل تغییر هستند و همان چهار شرط آزمون کاربری را تشکیل می دهند (بخش ۳-۹-۲):

۱. **خاموش:** بدون هیچ لایه ارگانیک؛ دوربین دقیقاً جهت کنترل را دنبال می کند.

۲. **نویز پرلین:** انحراف مستقیماً از نویز پرلین یک بعدی به دست می آید. برای هر محور یک نقطه شروع متفاوت در نظر گرفته می شود تا دو محور مستقل باشند. دامنه ۱/۵ درجه و فرکانس ۱/۲ هرتز است:

$$(۳-۱۱) \quad O^{yaw}(t) = A \cdot P(ft), \quad O^{pitch}(t) = A \cdot P(ft + ۵۷.۳)$$

۳. **Camera Shake آنریل:** یک Camera Shake با الگوی نویز پرلین که با ابزارهای خود آنریل ساخته شده است، از طریق مدیر دوربین بازیکن اجرا می شود (Epic Games, n.d). پارامترهای آن [] است.

۴. **مدل:** باقی مانده هایی که از پایتون دریافت می شوند در انحراف جمع می شوند.

در حالت مدل، هر باقی مانده دریافتی یک بار به انحراف اضافه می شود و سپس انحراف با یک ضریب نشت کمی به سمت صفر برمی گردد و در یک بازه مشخص محدود می شود:

$$(۳-۱۲) \quad O_n = clip((1 - \lambda)(O_{n-1} + r_n), -O_{max}, O_{max})$$

که در آن r_n آخرین باقی مانده دریافتی (یا صفر اگر پیام جدیدی نرسیده باشد)، $\lambda = ۰.۰۵$ ضریب نشت در هر فریم و $O_{max} = ۳$ درجه است. دلیل وجود نشت این است که خطاهای کوچک پیش بینی در طول زمان جمع می شوند و بدون نشت، انحراف دوربین به تدریج از جهت کنترل دور می شود. دلیل وجود سقف هم این است که در صورت هر نوع خطا در مدل یا ارتباط، دوربین هیچ وقت بیشتر از ۳ درجه از جهتی که بازیکن انتخاب کرده منحرف نشود. علاوه بر این، اگر در ۰/۲ ثانیه گذشته پیامی از پایتون نرسیده باشد، باقی مانده صفر در نظر گرفته می شود و انحراف به تدریج به صفر برمی گردد.

یک نکته در پیاده‌سازی فعلی این است که مدل با نرخ ۳۰ هرتز کار می‌کند ولی آنریل معمولاً با نرخ بیشتری رندر می‌کند، بنابراین هر باقی‌مانده فقط در یک فریم اعمال می‌شود و در فریم‌های بین دو پیش‌بینی، انحراف تغییری جزو نشت ندارد. پخش کردن هر باقی‌مانده در طول فریم‌های بین دو پیش‌بینی می‌تواند حرکت را نرم‌تر کند [۱].

۳-۷-۲- ارتباط OSC

ارتباط بین آنریل و پایتون با پروتکل OSC انجام می‌شود. این پروتکل در ابتدا برای ارتباط رایانه‌ها با سینتی‌سایزرها و تجهیزات صوتی طراحی شد (Wright & Freed, ۱۹۹۷) و پیام‌های آن شامل یک آدرس به شکل مسیر و تعدادی آرگومان هستند. OSC معمولاً روی پروتکل UDP (Postel, ۱۹۸۰) منتقل می‌شود. در UDP، برخلاف TCP، تحویل بسته‌ها تضمین نمی‌شود و بسته گم‌شده دوباره ارسال نمی‌شود. برای این کاربرد همین ویژگی مناسب است: اگر پیامی گم شود، ارسال دوباره آن فایده‌ای ندارد چون تا آن زمان پیام جدیدتری رسیده است. آنریل از طریق افزونه OSC، و پایتون از طریق کتابخانه python-osc از این پروتکل پشتیبانی می‌کنند. هر دو برنامه روی یک رایانه اجرا می‌شوند و از آدرس محلی ۱۲۷/۰/۰/۱ استفاده می‌کنند. پیام‌های استفاده‌شده در جدول ۳-۵ آمده‌اند.

جدول ۳-۵- پیام‌های OSC بین آنریل و پایتون

پیام	جهت و پورت	آرگومان‌ها	زمان ارسال
/oc/state	آنریل ← پایتون، پورت ۷۰۰۱	شماره فریم، طول فریم (ثانیه)، قصد افقی و عمودی (درجه)، سرعت (متر بر ثانیه)	هر فریم آنریل
/oc/residual	پایتون ← آنریل، پورت ۷۰۰۰	باقی‌مانده افقی و عمودی (درجه)	هر گام ۳۰ هرتز

شماره پورت‌ها ثابت نیستند و در هر دو برنامه قابل تنظیم هستند. شماره فریم فقط برای هم‌تراز کردن لاگ‌های دو برنامه ارسال می‌شود.

۳-۷-۳- حلقه اجرای زنده در پایتون

برنامه پایتون از سه بخش همزمان تشکیل شده است: دریافت پیام‌های OSC، گرفتن تصویر پنجره بازی، و حلقه اصلی. بخش گرفتن تصویر در یک رشته جداگانه اجرا می‌شود و به‌طور مداوم تصویر پنجره بازی را با کتابخانه mss می‌گیرد و فقط آخرین تصویر را نگه می‌دارد. به این ترتیب حلقه اصلی هیچ‌وقت منتظر گرفتن تصویر نمی‌ماند. حلقه اصلی در هر دور این کارها را انجام می‌دهد:

۱. همه پیام‌های state که از دور قبل رسیده‌اند خوانده می‌شوند. قصد و طول فریم آن‌ها با هم جمع می‌شود و هر وقت مجموع طول فریم‌ها به یک‌سی‌ام ثانیه رسید، یک سطر جدید به تاریخچه اضافه می‌شود. این سطر شامل قصد جمع‌شده، آخرین پیش‌بینی مدل به جای باقی‌مانده و آخرین سرعت است. خواندن همه پیام‌های موجود باعث می‌شود حلقه هیچ‌وقت از آنریل عقب نیفتد.
 ۲. اگر سطر جدیدی اضافه شده باشد، آخرین تصویر گرفته‌شده روی کارت گرافیک منتقل، به اندازه ۲۲۴ در ۲۲۴ تغییر اندازه داده و نرمال می‌شود.
 ۳. تاریخچه با پارامترهای ذخیره‌شده نرمال می‌شود و مدل باقی‌مانده را پیش‌بینی می‌کند. خروجی به واحد درجه برگردانده می‌شود.
 ۴. باقی‌مانده، در صورت نیاز ضرب در یک ضریب بهره، با پیام residual به آنریل فرستاده می‌شود.
- ضریب بهره برای این در نظر گرفته شده است که در آزمایش‌های اولیه، انحراف معیار خروجی مدل حدود نصف انحراف معیار باقی‌مانده واقعی بود؛ این همان اثر میانگین‌گیری است که در بخش ۳-۶-۱ به آن اشاره شد. مقدار نهایی ضریب بهره در فصل چهارم بر اساس داده‌های کامل تعیین می‌شود [۱].

۳-۸- روش اندازه‌گیری تأخیر

برای پاسخ به سؤال سوم پژوهش، زمان هر مرحله از حلقه اصلی با ساعت دقیق سیستم اندازه‌گیری و در یک فایل CSV ثبت می‌شود. مهم‌ترین معیار، تأخیر کل است که از لحظه دریافت پیام state تا لحظه ارسال پیام residual تعریف می‌شود:

$$(۳-۱۳) \quad T_{total} = T_{wait} + T_{capture} + T_{pre} + T_{model} + T_{send}$$

که در آن $T_{capture}$ زمان برداشتن آخرین تصویر، T_{pre} زمان پیش‌پردازش تصویر، T_{model} زمان اجرای مدل، T_{send} زمان ارسال پیام و T_{wait} زمان انتظار پیام در صف است. علاوه بر این، «سن تصویر» هم ثبت می‌شود، یعنی مدت زمانی که از گرفتن تصویر تا استفاده از آن در مدل گذشته است. برای اینکه زمان‌های ثبت‌شده کارت گرافیک دقیق باشند، پیش و پس از هر مرحله کارت گرافیک همگام‌سازی می‌شود. اندازه‌گیری در حالی انجام می‌شود که آنریل در همان رایانه در حال رندر است، تا شرایط به استفاده واقعی نزدیک باشد. از توزیع زمان‌ها، میانه و صدک‌های ۹۵ و ۹۹ گزارش می‌شود، چون در یک سیستم زنده، تأخیرهای گاه‌به‌گاه به اندازه تأخیر متوسط اهمیت دارند.

معیار پذیرش این است که تأخیر کل کمتر از ۳۳ میلی‌ثانیه، یعنی کمتر از یک گام ۳۰ هرتز، باشد. اگر تأخیر از این مقدار بیشتر شود، پیش‌بینی هر گام پس از رسیدن گام بعدی آماده می‌شود و سیستم از داده‌ها عقب می‌افتد. باید توجه داشت که این اندازه‌گیری زمان اعمال باقی‌مانده در آنریل و نمایش آن روی صفحه را شامل نمی‌شود؛ این زمان‌ها به رندر آنریل و نمایشگر بستگی دارند و در هر چهار حالت دوربین یکسان هستند.

۳-۹- طراحی ارزیابی

۳-۹-۱- ارزیابی عینی

ارزیابی عینی روی مجموعه آزمون، یعنی ضبط‌های شرکت‌کننده‌ای که در آموزش دیده نشده است، انجام می‌شود. معیارها در جدول ۳-۶ آمده‌اند.

جدول ۳-۶- معیارهای ارزیابی عینی

معیار	تعریف	هدف
میانگین قدر مطلق خطا (درجه)	اختلاف پیش‌بینی و باقی‌مانده واقعی	دقت پیش‌بینی
نسبت به خط پایه صفر	خطای مدل تقسیم بر خطای پیش‌بینی صفر	آیا مدل از «بدون لایه ارگانیک» بهتر است
نسبت انحراف معیار	انحراف معیار پیش‌بینی تقسیم بر انحراف معیار واقعی	آیا دامنه حرکت حفظ شده یا خروجی کوچک شده است
همبستگی	همبستگی پیرسون پیش‌بینی و مقدار واقعی، برای هر محور	شباهت شکل حرکت
طیف توان	مقایسه طیف توان پیش‌بینی و مقدار واقعی در باندهای فرکانسی	آیا ویژگی‌های فرکانسی (مثل حرکت گام) بازسازی شده است

مدل کامل با این روش‌ها مقایسه می‌شود: پیش‌بینی صفر، نویز پرلین با دامنه برابر (بخش ۳-۹-۳)، و دو نسخه مقایسه‌ای «فقط حرکت» و «بدون توجه» (بخش ۳-۵-۴). مقایسه با نویز پرلین فقط برای معیارهای طیفی و نسبت انحراف معیار معنا دارد، چون نویز پرلین پیش‌بینی نمی‌کند. علاوه بر این، وزن‌های توجه روی چند کلیپ نمونه

نمایش داده می‌شوند تا بررسی شود آیا مدل به نواحی معناداری از تصویر، مثل شخص در حال حرکت، توجه می‌کند یا نه.

۳-۹-۲- آزمون کاربری

برای پاسخ به سؤال چهارم پژوهش، یک آزمون کاربری از نوع تماشای کلیپ طراحی شده است. در این آزمون شرکت‌کنندگان بازی نمی‌کنند، بلکه کلیپ‌های کوتاهی از بازی را تماشا کرده و آن‌ها را ارزیابی می‌کنند. دلیل این انتخاب این است که در بازی کردن، رفتار هر شرکت‌کننده متفاوت است و مقایسه منصفانه چهار حالت دوربین دشوار می‌شود. در آزمون تماشایی، هر چهار حالت دقیقاً روی یک مسیر و یک حرکت بازیکن اعمال می‌شوند و تنها تفاوت کلیپ‌ها لایه دوربین است.

برای ساخت کلیپ‌ها، ورودی بازیکن (حرکت و ماوس) در چند مسیر مشخص در محیط اداری ضبط و سپس برای هر چهار حالت دوباره پخش و فیلم‌برداری می‌شود [۱]. مسیرها شامل راه رفتن در راهرو، دنبال کردن یک کاراکتر متحرک و چرخش به سمت یک نقطه هستند تا با سناریوهای ضبط داده متناظر باشند. هر کلیپ حدود [۱] ثانیه طول دارد. شرایط آزمون در جدول ۳-۷ آمده است.

جدول ۳-۷- شرط‌های آزمون کاربری

شرط	لایه دوربین
خاموش	بدون لایه ارگانیک
پرلین	نویز پرلین با دامنه برابر با شرط مدل
Camera Shake	Camera Shake آنریل با دامنه برابر با شرط مدل
مدل	باقی مانده پیش‌بینی شده توسط مدل پیشنهادی

طرح آزمون درون گروهی است؛ یعنی هر شرکت کننده همه کلیپ ها را می بیند. ترتیب نمایش شرط ها با یک طرح مربع لاتین بین شرکت کنندگان متوازن می شود تا اثر ترتیب و خستگی حذف شود. شرکت کنندگان نمی دانند هر کلیپ مربوط به کدام شرط است. پس از هر کلیپ، شرکت کننده به این سؤال ها در مقیاس هفت درجه ای لیکرت پاسخ می دهد: حرکت دوربین چقدر طبیعی و شبیه به فیلم برداری انسان بود، چقدر حس حضور در محیط داشت، و چقدر احساس ناراحتی کرد. پرسش نامه (Kennedy et al., ۱۹۹۳) SSQ پیش و پس از کل جلسه تکمیل می شود. در پایان جلسه هم از شرکت کننده خواسته می شود کلیپ ها را از نظر طبیعی بودن به ترتیب مرتب کند. تعداد شرکت کنندگان [] نفر است.

از آنجا که داده های لیکرت ترتیبی هستند، برای مقایسه چهار شرط از آزمون ناپارامتری فریدمن (Friedman, ۱۹۳۷) استفاده می شود. در صورت معنادار بودن، مقایسه زوجی شرط ها با آزمون رتبه علامت دار ویلکاکسون (Wilcoxon, ۱۹۴۵) و اصلاح هولم برای مقایسه های چندگانه (Holm, ۱۹۷۹) انجام می شود. تغییر نمره SSQ بین پیش و پس از جلسه هم با آزمون ویلکاکسون بررسی می شود. سطح معناداری ۰/۰۵ در نظر گرفته می شود.

پیش از شروع آزمون، هدف و روند آن برای شرکت کننده توضیح داده می شود و رضایت نامه آگاهانه از او گرفته می شود. شرکت کننده در هر زمان می تواند آزمون را بدون ذکر دلیل متوقف کند. اگر شرکت کننده علائم بیماری حرکتی را گزارش کند، آزمون متوقف می شود. هیچ اطلاعات شناسایی کننده ای همراه با پاسخ ها ذخیره نمی شود. مجوز انجام آزمون از [] دانشکده گرفته می شود.

۳-۹-۳- برابر کردن دامنه حرکت

یکی از خطرهای مقایسه روش های مختلف لرزش این است که تفاوت نتایج به جای شکل حرکت، از تفاوت مقدار آن ناشی شود؛ مثلاً ممکن است شرکت کنندگان هر روشی را که دامنه کمتری دارد طبیعی تر یا راحت تر بدانند. برای جلوگیری از این مشکل، دامنه انحراف دوربین در سه شرط پرلین، Camera Shake و مدل برابر می شود. برای این

کار، ابتدا جذر میانگین مربعات (RMS) انحراف دوربین در شرط مدل روی هر مسیر اندازه گیری می شود و سپس دامنه دو روش دیگر با یک ضریب طوری تنظیم می شود که RMS آنها با شرط مدل برابر شود:

$$(۳-۱۴) \quad A'_c = A_c \cdot \frac{RMS(O_{model})}{RMS(O_c)}$$

که در آن A_c و A'_c دامنه اولیه و تنظیم شده روش c و O انحراف دوربین است. به این ترتیب هر سه روش به یک اندازه حرکت به تصویر اضافه می کنند و تنها تفاوت آنها در شکل و الگوی زمانی حرکت است.

۳-۱۰- جمع بندی

در این فصل روش انجام پژوهش شرح داده شد. داده از ضبط ویدیو و ژيروسکوپ گوشی همراه در یک محیط اداری به دست می آید، با مقایسه جریان نوری و ژيروسکوپ همگام می شود و با یک فیلتر بدون تأخیر فاز به دو بخش قصد و باقی مانده تقسیم می شود. مدل پیشنهادی با استفاده از یک شبکه تصویری ثابت، یک GRU کوچک و یک لایه توجه متقاطع، باقی مانده گام بعد را پیش بینی می کند و با تابع هزینه ای آموزش می بیند که علاوه بر دقت، جهت حرکت و تغییرات بین گام ها را هم در نظر می گیرد. در زمان اجرا، مدل در یک برنامه جداگانه اجرا می شود و از طریق OSC با آنریل ارتباط دارد، و کامپوننت دوربین در آنریل خروجی آن را به صورت محدود و ایمن روی دوربین اعمال می کند. در نهایت، روش ارزیابی عینی مدل، اندازه گیری تأخیر و آزمون کاربری با چهار شرط و دامنه برابر طراحی شد. نتایج این ارزیابی ها در فصل چهارم ارائه می شود.

منابع فصل سوم

- Akhmetyanov, A., Kornilova, A., Faizullin, M., Pozo, D., & Ferrer, G. (۲۰۲۱). Sub-millisecond video synchronization of multiple Android smartphones. ۲۰۲۱ *IEEE Sensors*.
<https://doi.org/10.1109/SENSORSE47087/2021/9639782>
- Ba, J. L., Kiros, J. R., & Hinton, G. E. (۲۰۱۶). Layer normalization. *arXiv preprint arXiv:1607.06650*.
- Bradski, G. (۲۰۰۰). The OpenCV library. *Dr. Dobbs Journal of Software Tools*, ۲۵ (۱۱), ۱۲۰-۱۲۵.

- Dosovitskiy, A., Beyer, L., Kolesnikov, A., Weissenborn, D., Zhai, X., Unterthiner, T., Dehghani, M., Minderer, M., Heigold, G., Gelly, S., Uszkoreit, J., & Houlsby, N. (2021). An image is worth 16x16 words: Transformers for image recognition at scale. *International Conference on Learning Representations (ICLR 2021)*.
- Epic Games. (n.d.). *Camera shakes in Unreal Engine* (Unreal Engine 5.0 documentation). Retrieved September 29, 2026, from https://dev.epicgames.com/documentation/en-us/unreal-engine/camera-shakes-in-unreal-engine?application_version=5.0
- Farnebäck, G. (2003). Two-frame motion estimation based on polynomial expansion. In J. Bigun & T. Gustavsson (Eds.), *Image Analysis (SCIA 2003)*, Lecture Notes in Computer Science, Vol. 2749, 363-370. Springer.
- Friedman, M. (1937). The use of ranks to avoid the assumption of normality implicit in the analysis of variance. *Journal of the American Statistical Association*, 32(200), 770-771.
- He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. *Proceedings of CVPR 2016*, 770-778.
- Hendrycks, D., & Gimpel, K. (2016). Gaussian error linear units (GELUs). *arXiv preprint arXiv:1606.08415*.
- Holm, S. (1979). A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics*, 2(2), 65-70.
- Karpenko, A., Jacobs, D., Baek, J., & Levoy, M. (2011). *Digital video stabilization and rolling shutter correction using gyroscopes* (Stanford Tech Report CTSR 2011-03). Stanford University.
- Kennedy, R. S., Lane, N. E., Berbaum, K. S., & Lilienthal, M. G. (1993). Simulator sickness questionnaire: An enhanced method for quantifying simulator sickness. *The International Journal of Aviation Psychology*, 3(3), 203-220.
- Kingma, D. P., & Ba, J. (2015). Adam: A method for stochastic optimization. *International Conference on Learning Representations (ICLR 2015)*. arXiv:1512.07488.
- Paszke, A., Gross, S., Massa, F., Lerer, A., Bradbury, J., Chanan, G., Killeen, T., Lin, Z., Gimelshein, N., Antiga, L., Desmaison, A., Kopf, A., Yang, E., DeVito, Z., Raison, M., Tejani, A., Chilamkurthy, S.,

- Steiner, B., Fang, L., ... Chintala, S. (2019). PyTorch: An imperative style, high-performance deep learning library. *Advances in Neural Information Processing Systems* 32.
- Postel, J. (1980). *User Datagram Protocol* (RFC 768). RFC Editor. <https://www.rfc-editor.org/rfc/rfc768>
- Virtanen, P., Gommers, R., Oliphant, T. E., Haberland, M., Reddy, T., ... SciPy 1.0 Contributors. (2020). SciPy 1.0: Fundamental algorithms for scientific computing in Python. *Nature Methods*, 17(3), 261-272.
- Wilcoxon, F. (1945). Individual comparisons by ranking methods. *Biometrics Bulletin*, 1(6), 80-83.
- Wright, M., & Freed, A. (1997). Open SoundControl: A new protocol for communicating with sound synthesizers. *Proceedings of the 1997 International Computer Music Conference (ICMC 1997)*, 101-104.